# Übersicht

# 4 Syntaktische Relationen: Konstituenz

# 4.1 Konstituentenstruktur

# 4.1.1 Eigenschaften der Konstituentenstruktur

- **Konstituentenanalyse** (IC-Analyse): **Zerlegung** syntaktischer Einheit in ihre Teile (Konstituenten) und Bildung von **Konstituentenklassen** (lexikalische und syntaktische Kategorien)
  → Ermittlung über **Konstituententests**
  → Ergebnis ist eine **hierarchisch gegliederte Struktur**

- **unmittelbare Konstituenten** sind die **maximalen Konstituenten** einer Einheit (aus denen sie unmittelbar zusammengesetzt ist)

- **Konstituenz: Teil-Ganzes-Beziehung** zwischen sprachlichen Einheiten (Konstituenten)
- Beziehung der **unmittelbaren Dominanz** zwischen Einheit und ihren unmittelbaren Konstituenten
- Beziehung der **Dominanz** zwischen Einheit X und der unmittelbare Konstituente Y; sowie zwischen X und Z, wenn Y Z dominiert

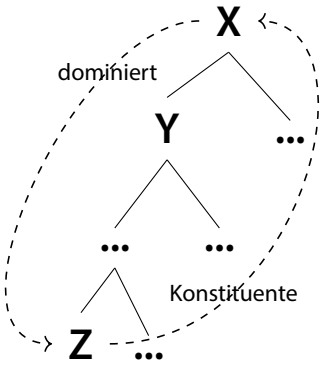


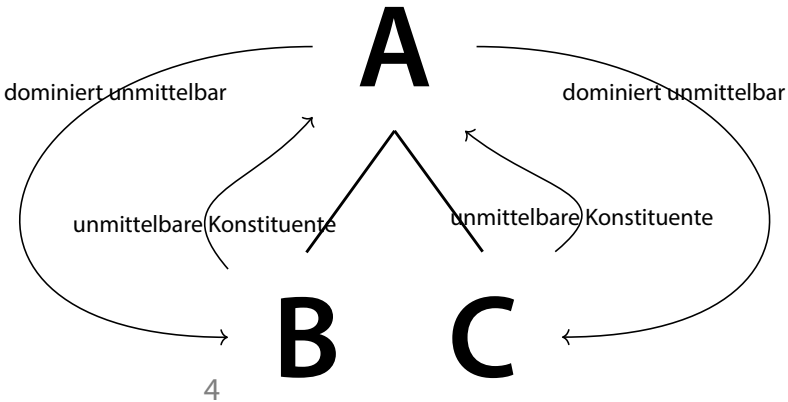

## Konstituentenstruktur

- **Konstituentenstruktur**: Menge der **durch die Relation der unmittelbaren Dominanz verbundenen Konstituenten**
- durch Bezug auf **Konstituentenklassen** (lexikalische und syntaktische Kategorien als Knoten) und Abstraktion von der Wortebene ergeben sich **Konstituenten-/Phrasenschemata von Einheiten mit gleicher Struktur**

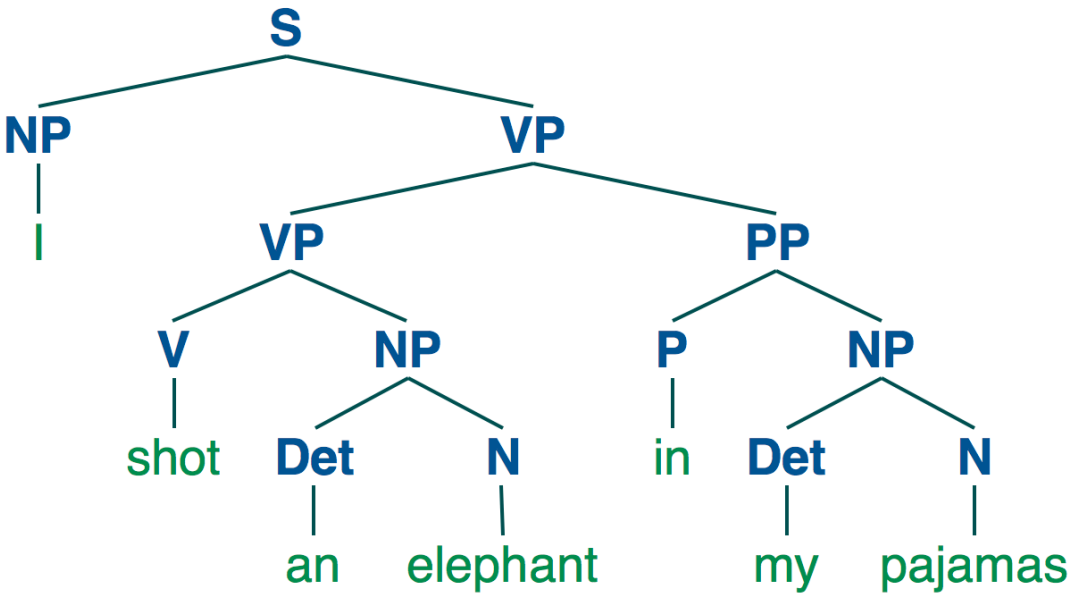


Abbildung 1: *Syntaxbaum als Repräsentation der Konstituentenstruktur*

## Übersicht Konstituentenstruktur:

- **Elemente der Struktur (Knoten)** $\rightarrow$ *Wörter, lexikalische und syntaktische Kategorien (Klassen nicht-elementarer Konstituenten)*
- **Relationen der Struktur (Kanten)** $\rightarrow$ *Teil-Ganzes-Beziehung; unmittelbare Dominanz des Mutterknotens über Tochterknoten*
- **syntaktische Kategorien** $\rightarrow$ *nichtterminale Knoten*
- **Strukturinformationen in Knoten des Syntaxbaums**

## Kopfprinzip

- jede Phrase hat einen **Kopf (auch: Phrasenkern)**
- alle anderen Wörter und Phrasen in der Phrase sind zum Kopf **dependent**
- Kopf vererbt **morphosyntaktische Merkmale** an Phrase
- Kopf steuert **syntaktisches Verhalten** der Konstituente im Satz
- Kopf bestimmt die **Phrasenkategorie** (Wortart X $\rightarrow$ Phrasenkat. XP)

## Kopf-Perkolation

- Merkmale der Phrase werden getragen von Kopf
- Köpfe werden im Syntaxbaum nach oben weitergereicht
- **Kopf-Perkolations-Regeln**:
  $\rightarrow$ head(NP) = head(N)
  $\rightarrow$ head(VP) = head(V)
  $\rightarrow$ head(S) = head(VP)
- wichtig u.a. für **lexikalisierte Grammatiken** sowie die **Transformation einer Phrasenstruktur- in eine Dependenzgrammatik**

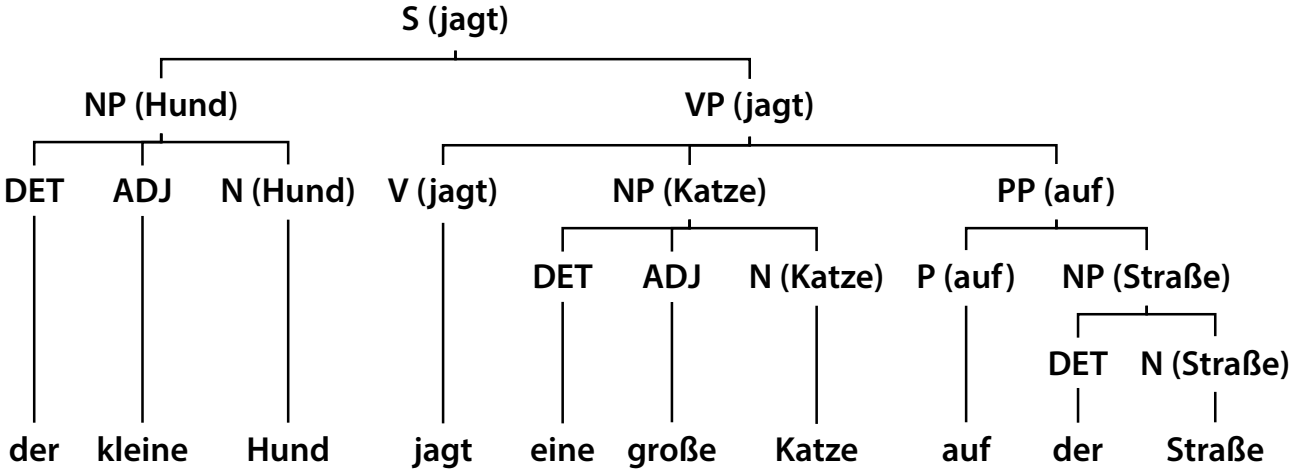


Abbildung 2: *Phrasenstruktur Transitiver Satz des Deutschen mit Kopfregeln*

## Diskontinuierliche Konstituenten

- ***long distance dependencies***
- Trennung von Teilkonstituenten einer Konstituente
- Problem für Baumdarstellung:
  $\rightarrow$ **Überkreuzung** = nicht-projektiv
- Lösung: **leere Knoten** (*empty nodes*: `0`, $\epsilon$, `t`, `NONE`)
  $\rightarrow$ *trace* (**Spur**): Konzept der Transformationsgrammatik

- **Transformationsgrammatik**:
  → Annahme: **Tiefen- und Oberflächenstruktur**
  → abstrakte vs. beobachtbare Form von Sätzen
  → z. B.: Annahme deutsche Tiefenstruktur der VP: OV (*den Hund sehen*)
  → **Transformationsregelanwendung** zur Erzeugung der Oberflächenstruktur: **läßt Spur zurück**

- im Englischen relativ begrenzt: z.B. Topikalisierung, Extraposition, **Wh-fronting**

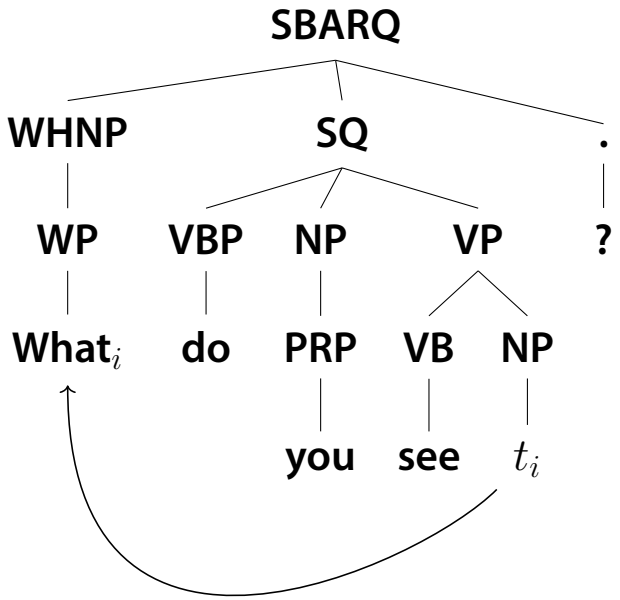


Abbildung 3: *Beispiel für Analyse* long-distance dependency *mit Spur (t)*

## Schema Einfacher Satz

- **allgemeines Satzschema: S = NP + VP**
  → Ergebnis von Konstituententests (Reduktion auf Zweiwort-Satz)
  → **Subjekt-NP und Verb interdependent**, also gegenseitig abhängig (sichtbar am **Verb-Agreement**)
  → Subjekt (Satzaussage) - Prädikat (Satzgegenstand)
  → abstrahiert von linearer Ordnung: **Wortstellung sprachabhängig**

- **VP = VERB +** ***dependents*** (Komplemente + Adjunkte)
  $\rightarrow$ Komplemente = obligatorische (valenzgeforderte) Erweiterungen
  $\rightarrow$ Adjunkte = nicht-obligatorisch Erweiterungen, Anzahl nicht begrenzt

- **NP = NOUN +** ***dependents*** (nominale Erweiterungen / Modifikatoren)

# 4.1.2 Konstituentenstruktur des Deutschen

- Phrasenschema VP:

  **V** + **(Komplemente|Adjunkte|ADVP)***

- Phrasenschema NP:

  **(DET | NPgen)** **(ADJP)*** **N** **(NPgen|von-PP)*** **(PP / RELS)***

  → komplexer Aufbau der Nominalphrase

  → Links-und Rechtserweiterungen

## Satzgrundstruktur

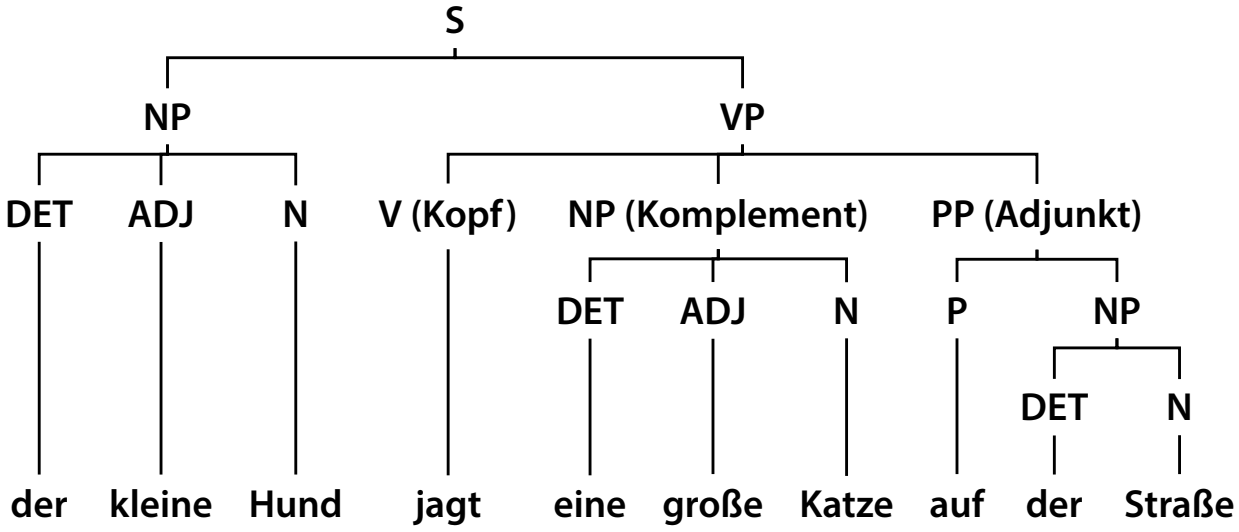


Abbildung 4: *Phrasenstruktur Transitiver Satz des Deutschen*

## NP-Struktur des Deutschen

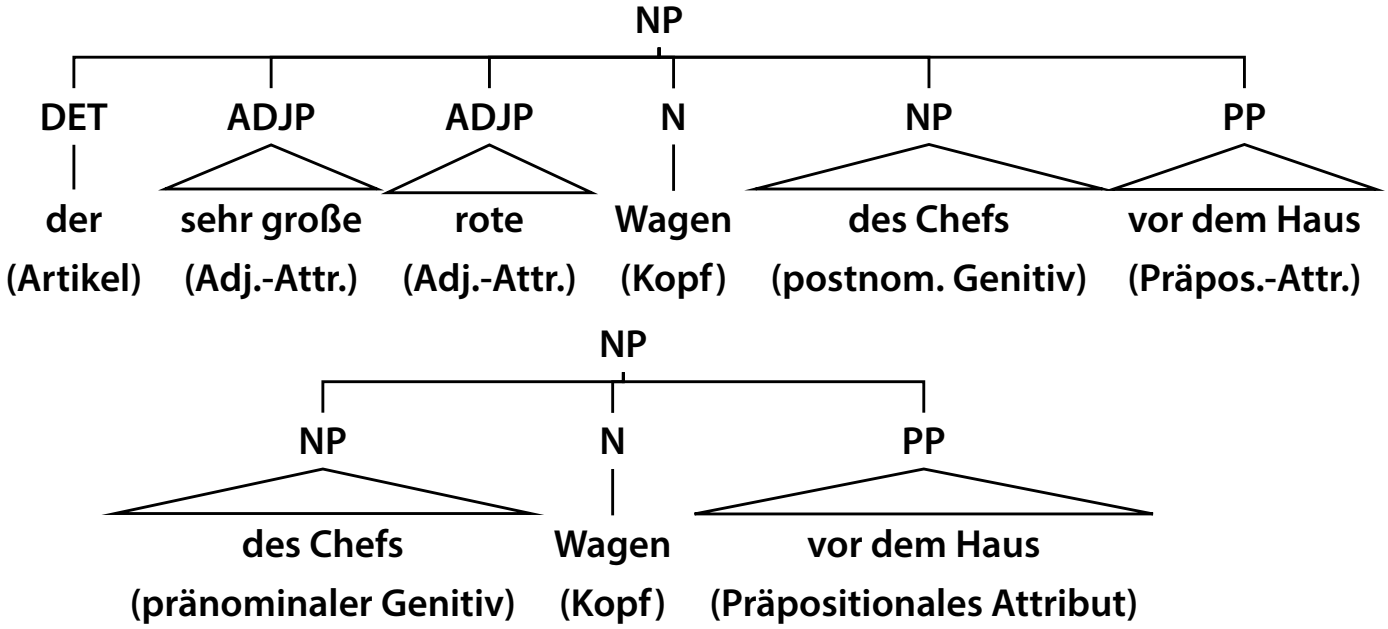


Abbildung 5: *NP-Konstruktionen Deutsch (2: Genitivattribut als Determinativ-Vertreter)*

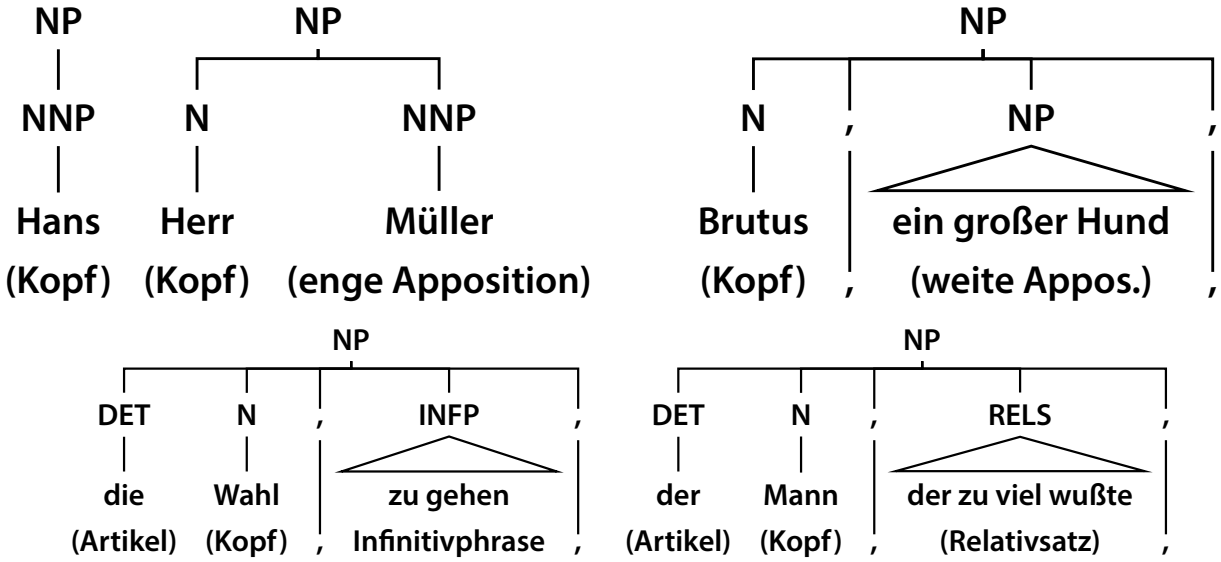


Abbildung 6: *NP-Konstruktionen Deutsch*

# 4.2 Modellierung mit kontextfreier Grammatik

# 4.2.1 Phrasenstrukturgrammatik

- **Syntax als Satzstrukturanalyse**:
  $\rightarrow$ Beschreibung der **syntaktischen Regeln, die den beobachtbaren Strukturen** zugrunde liegen (Grammatik)

- **Konstituenten-/Phrasenstruktur** natürlicher Sprache ist formal **beschreibbar durch eine kontextfreie Grammatik (CFG)**
  $\rightarrow$ **Phrasenstrukturgrammatik** im engeren Sinne (PSG)
  $\rightarrow$ Regeln der **Verkettung von lexikalischen und phrasalen Kategoriensymbolen** (Nicht-Terminale)

- **syntaktische Regel**: bestimmt, zu welchen **Klassen die unmittelbaren Konstituenten einer syntaktischen Kategorie** gehören: $NP \rightarrow DET\ N\ PP$
- **lexikalische Regel**: bestimmt die **Zugehörigkeit einer elementaren Konstituente (Wort) zu einer lexikalischen Kategorie**: $N \rightarrow Hund$

## PSG-Regeln als Produktionsregeln:

- PSG-Regeln können als **Konstruktionsanweisung für Syntaxbäume** interpretiert werden: $S \rightarrow NP\ VP$
  $\rightarrow$ 'expandiere S zu Folge NP + VP'

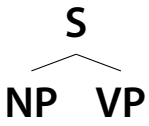


- PSG-Regel definiert **Relation der unmittelbaren Dominanz zwischen Mutterknoten und Tochterknoten**
  $\rightarrow$ 'S dominiert unmittelbar NP und VP'
  $\rightarrow$ 'S dominiert vollständig die Folge NP + VP'

- PSG **erkennt durch Ableitung** Sätze als zur Sprache gehörig und weist ihnen die ihren Regeln entsprechende **Strukturbeschreibung** zu
  $\rightarrow$ Strukturbeschreibung = die auf Kategorien bezugnehmende **Konstituentenstruktur**
  $\rightarrow$ 'Die Folge NP + VP ist ein S'

**Formale Grammatik:**

- **besteht aus:**
  - **Startsymbol**
  - **Nichtterminalsymbole**
    $\rightarrow$ Metasymbole
  - **Terminalsymbole**
    $\rightarrow$ Alphabet, Lexikon
  - **Produktionsregeln**
    $\rightarrow$ durch Einschränkungen der Regeln ergeben sich Sprachen verschiedener Komplexität (Chomsky-Hierarchie)

## Kontextfreie Grammatik:

- **CFG-Einschränkung:**
  $\rightarrow$ links nur ein Nichtterminalsymbol: $S \rightarrow NP\ VP$
  $\rightarrow$ Ersetzung unabhängig von Kontext (Kontextfreiheit)
- **syntaktische Regeln:** $NP \rightarrow Det\ N\ (PP)$
  $\rightarrow$ Ersetzungsregeln (linke mit rechter Seite)
  $\rightarrow$ links: syntaktische Kategorien (Phrasen/Satzknoten)
  $\rightarrow$ rechts: obligatorische und optionale Nichtterminale (syntaktische + lexikalische Kategorien)
- **Rekursion:** $NP \rightarrow Det\ N\ (PP)$, $PP \rightarrow P\ NP$

- **lexikalische Regeln:**

  $N \rightarrow$ *'Hund'*

  $N \rightarrow$ *'Katze'*

  $Det \rightarrow$ *'der'* | *'die'*

  $\rightarrow$ Zuordnung lexikalische Kategorien/Wortarten (Präterminale) zu Lexemen (Terminale)

- **Wortarten (=lexikalische Kategorien):** $\rightarrow$ *Präterminale*
- **Lexeme:** $\rightarrow$ *Terminale (Alphabet)*

## PSG-Regel-Konventionen:

- Regel mit fakultativen Elementen:

  $NP \rightarrow (DET)\ N$

  äquivalent zu:

  $NP \rightarrow DET\ N \mid N$

  äquivalent zu:

  $NP \rightarrow DET\ N$

  $NP \rightarrow N$

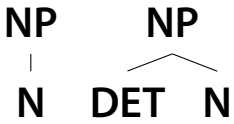

## Ableitung als top-down Erzeugung (Linksableitung):

$$G =< \{S, NP, VP, DET, N, V\}, \{das, Tier, Ding, sieht\}, R, S >$$

$$R = \{S \rightarrow NP\ VP, NP \rightarrow DET\ N, VP \rightarrow V\ NP,$$
$$DET \rightarrow das, N \rightarrow Tier, N \rightarrow Ding, V \rightarrow sieht\}$$

| | | | |
|---|---|---|---|
| S | $\Rightarrow$ | NP VP | (S $\rightarrow$ NP VP) |
| | $\Rightarrow$ | DET N VP | (NP $\rightarrow$ DET N) |
| | $\Rightarrow$ | das N VP | (DET $\rightarrow$ das) |
| | $\Rightarrow$ | das Tier VP | (N $\rightarrow$ Tier) |
| | $\Rightarrow$ | das Tier V NP | (VP $\rightarrow$ V NP) |
| | $\Rightarrow$ | das Tier sieht NP | (V $\rightarrow$ sieht) |
| | $\Rightarrow$ | das Tier sieht DET N | (NP $\rightarrow$ DET N) |
| | $\Rightarrow$ | das Tier sieht das N | (DET $\rightarrow$ das) |
| | $\Rightarrow$ | das Tier sieht das Ding | (N $\rightarrow$ Ding) |

Auflistung 1: *NLTK: Kontextfreie Grammatik (grammar1.cfg)*

```
1 ###### Syntaktische Regeln ######
2         S → NP VP
3         NP → DET N
4         VP → V NP NP
5
6 ###### Lexikalische Regeln ######
7         DET → "der" | "die" | "das"
8         N → "Mann" | "Frau" | "Buch"
9         V → "gibt" | "schenkt"
```

Auflistung 2: *NLTK: Erkennung und Strukturwiedergabe*

```
1
2  grammar = nltk.CFG.fromstring("""
3      S → NP VP
4      NP → DET N
5      DET → "der" | "die" | "das"
6      N → "Mann" | "Frau" | "Buch"
7      VP → V NP NP
8      V → "gibt" | "schenkt"
9      """)
10
11 sent = 'der Mann gibt der Frau das
     Buch'.split()
12 parser = nltk.ChartParser(grammar,trace=0)
13
14
```

```
15 for tree in parser.parse(sent):
16     print(tree);tree.pretty_print()
17 #(S
18 #  (NP (DET der) (N Mann))
19 #  (VP (V gibt) (NP (DET der) (N Frau)) (NP
     (DET das) (N Buch))))
20
21                     S
22       ______________|_______
23      |                      VP
24      |              ________|________
25      NP            |        NP       NP
26   ___|___          |     ___|___   ___|___
27 DET     N          V   DET     N DET     N
28  |      |          |    |      |   |      |
29 der    Mann       gibt der    Frau das   Buch
```

```
30
31
32 #Übergenerierung:
33 for sentence in generate(grammar, depth=5):
34     print(' '.join(sentence))
35 der Mann gibt der Mann der Mann
36 der Mann gibt der Mann der Frau
37 der Mann gibt der Mann der Buch
38 der Mann gibt der Mann die Mann
39 der Mann gibt der Mann die Frau
40 der Mann gibt der Mann die Buch
41 der Mann gibt der Mann das Mann
42 der Mann gibt der Mann das Frau
43 der Mann gibt der Mann das Buch
```

## Rekursive Kategorien

- **Rekursiver Aufbau natürlicher Sprachen**
  $\rightarrow$ erklärt **Nicht-Endlichkeit** natürlicher Sprachen
  $\rightarrow$ endliche Anzahl an syntaktischen Regeln, aber unbegrenzte Anzahl an bildbaren Sätzen (z. B.: durch Hinzufügung von Adjunkten)
  $\rightarrow$ modellierbar mit **rekursiven Phrasenstrukturregeln**
  $\rightarrow$ Erzeugung **verschachtelter Strukturen**

- **rekursive Kategorien**: NP, PP, Relativsätze, Komplementsätze

- **direkte Rekursion**: Ausgabe einer Regel dient als Eingabe der gleichen Regel:
  **NP** $\rightarrow$ DET N **NP**
  *der Sohn der Frau des Mannes ...*

- **indirekte Rekursion**: Ausgabe einer Regel dient als Eingabe einer anderen Regel:
  NP $\rightarrow$ DET N PP
  PP $\rightarrow$ P NP
  *der Mann in dem Wald in dem Land ...*
  *neben dem Mann in dem Wald in dem Land ...*

Auflistung 3: *Grammatik mit Rekursion*

```
1 S → NP
2 PP → P NP
3 NP → N | N PP
4 N → 'Hund' | 'Katze'
5 P → 'mit'
```

Auflistung 4: *NLTK: Generierung von Sätzen mit rekursiver Kategorie*

```
# http://www.nltk.org/howto/generate.html
from nltk.parse.generate import generate

grammar = nltk.CFG.fromstring("""
    S → NP
    PP → P NP
    NP → N | N PP
    N → 'Hund' | 'Katze'
    P → 'mit'
    """)
for sentence in generate(grammar, depth=8):
    print(' '.join(sentence))
# Hund
# Katze
# Hund mit Hund
```

```
16 # Hund mit Katze
17 # Hund mit Hund mit Hund
18 # Hund mit Hund mit Katze
19 # Hund mit Katze mit Hund
20 # Hund mit Katze mit Katze
21 # Katze mit Hund
22 # Katze mit Katze
23 # Katze mit Hund mit Hund
24 # Katze mit Hund mit Katze
25 # Katze mit Katze mit Hund
26 # Katze mit Katze mit Katze
```

# 4.2.2 Phrasenstrukturregeln des Deutschen

**Adverbphrase `ADVP, AVP`:**

- Phrasenschema ADVP: **(PRT)** **ADV**
- Produktionsregeln ADVP:

$ADVP \rightarrow PRT\ ADV$
$ADVP \rightarrow ADV$

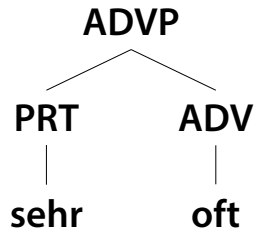

**Präpositionalphrase PP:**

- Phrasenschema PP: **(PRT)** **<u>P</u>** **NP**
- Produktionsregeln PP:

$PP \rightarrow P\ NP$
$PP \rightarrow PRT\ P\ NP$

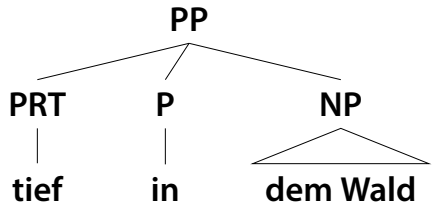

**Adjektivphrase `ADJP, AP`:**

- Phrasenschema ADJP: **(PP)* (PRT)** **<u>ADJ</u>**

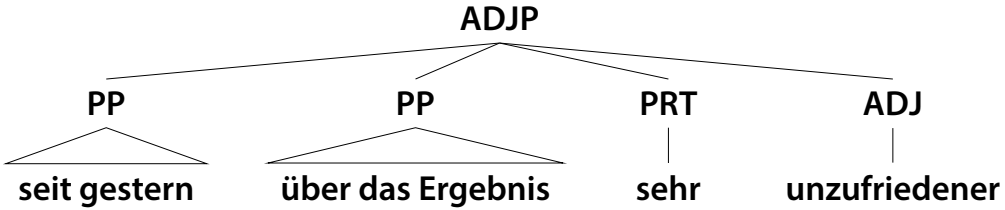


- Produktionsregeln ADJP (flacher Aufbau ohne Rekursion):
  $ADJP \rightarrow ADJ$
  $ADJP \rightarrow PRT\ ADJ$
  $ADJP \rightarrow PP\ ADJP$
  $ADJP \rightarrow PP\ PRT\ ADJP$
  $ADJP \rightarrow PP\ PP\ ADJP$ usw.

**Adjektivphrase mit rekursivem Strukturaufbau:**

- Phrasenschema ADJP: **(PP)* (PRT)** **ADJ**
- Produktionsregeln ADJP (rekursiver Aufbau):
  $ADJP \rightarrow PP\ ADJP$ (rekursive Regel)
  $ADJP \rightarrow PRT\ ADJ$
  $ADJP \rightarrow ADJ$

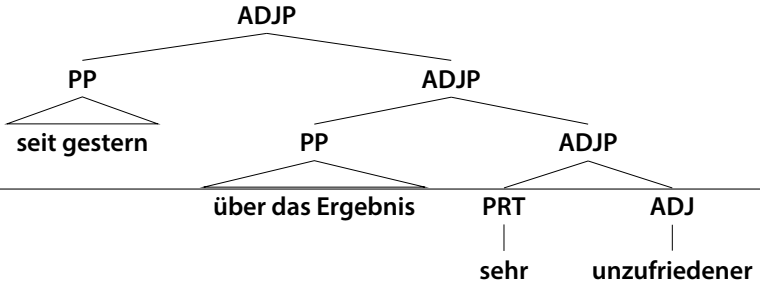

## Verbalphrase VP:

- Phrasenschema VP (vereinfacht):

**V + (Komplemente|Adjunkte)***

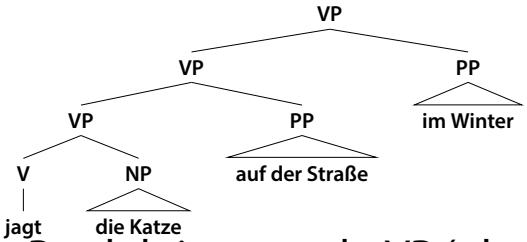


- Produktionsregeln VP (ohne AdvP):

  $VP \rightarrow VP\ PP$ (Adjunkte)

  $VP \rightarrow V\ NP$ (1 Komplement)

  $VP \rightarrow V$ (ohne Komplemente, intransitiv)

**Nominalphrase `NP`:**

- Phrasenschema NP (vereinfacht):

  **(DET) (ADJP)* <u>N</u> (PP)***

- Produktionsregeln NP (flacher Aufbau ohne Rekursion):

  $NP \rightarrow N \mid DET\ N$

  $NP \rightarrow ADJP\ N \mid DET\ ADJP\ N$

  $NP \rightarrow N\ PP \mid N\ PP$

  $NP \rightarrow ADJP\ N \mid ADJP\ N\ PP$

  usw.

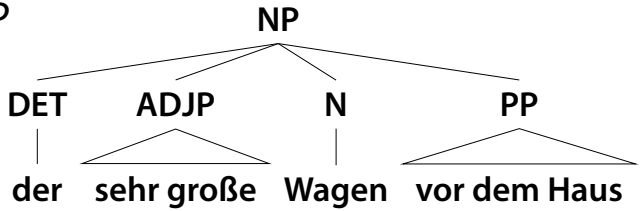

## Nominalphrase mit rekursivem Strukturaufbau (vorläufig):

- Phrasenschema NP (vereinfacht):

**(DET) (ADJP)* <u>N</u> (PP)***

$NP \rightarrow N$

$NP \rightarrow ADJP\ NP$ (rekurs. Linksattr.)

$NP \rightarrow NP\ PP$ (rekurs. Rechtsattr.)

$NP \rightarrow DET\ NP$ (?)

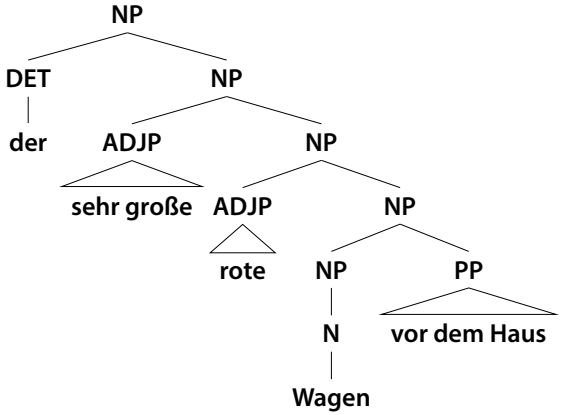

## Problem rekursive DET-Regel

- Mit der Regel $NP \rightarrow DET\ NP$ können zwar NPs gemäß des Phrasenschemas abgeleitet werden
- die Grammatik ist aber stark **übergenerierend** und damit kein adäquates Modell des NP-internen Strukturaufbaus
  $\rightarrow$ **Übergenerierung 1**: DET rekursiv wiederholbar an erster Position (richtige Strukturposition aber falsche Anzahl)
  $\rightarrow$ **Übergenerierung 2**: DET wiederholbar an falscher Strukturposition (z. B.: ADJP DET N)
- Strukturbegrenzung notwendig ($\rightarrow$ X-Bar)

Auflistung 5: *NLTK: Erkennung und (Über-)Generierung vorläufiger NP-Grammatik*

```
grammar = nltk.CFG.fromstring("""
    NP → ADJP NP
    NP → NP PP
    NP → N
    NP → DET NP
    N → 'Nomen'
    DET → 'das'
    ADJP → 'schöne'
    PP → 'darin'
    """)
sent = 'das schöne schöne Nomen darin
  darin'.split()
parser = nltk.ChartParser(grammar,trace=0)
for tree in parser.parse(sent):
    print(tree)
```

```
15 (NP
16   (NP
17     (NP
18       (DET das)
19       (NP (ADJP schöne) (NP (ADJP schöne) (NP
           (N Nomen)))))
20     (PP darin))
21   (PP darin))
22
23 for sentence in generate(grammar, depth=9):
24     print(' '.join(sentence))
25  #...
26 #das das schöne das schöne Nomen darin
27 #...
```

# Satzableitung aus den Grammatikregeln (mit $S \rightarrow NP\ VP$)

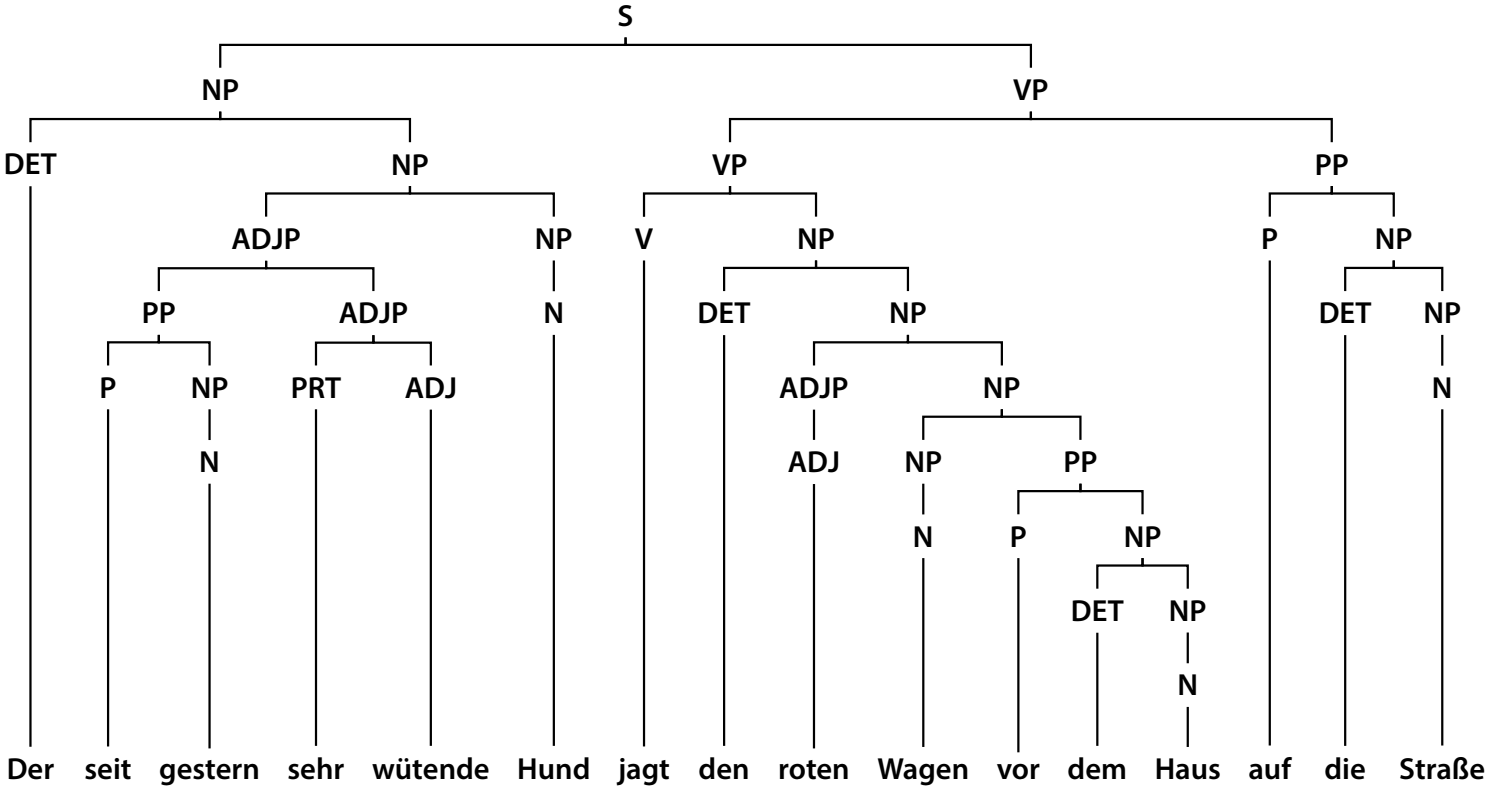

# 4.3 X-Bar-Phrasenstrukturschema

- Entwicklung durch Chomsky im Rahmen der *Government& Binding*-Theorie
- ursprüngliches Symbol: Balken (*bar*): $\bar{X}$
- **Beschränkung der Struktur von Phrasen**
  $\rightarrow$ **binäre** Verzweigung ($A \rightarrow B\ C$)
  $\rightarrow$ Einführung **phrasaler Zwischenebene** ($\bar{X}$ oder $X'$)
  $\rightarrow$ **gleicher Strukturaufbau für alle Phrasenarten** ($X$ als Wortart-Variable)

## Motivation für X-Bar-Schema

- bisher: **Anzahl und Art unmittelbarer Konstituenten einer Phrase nicht beschränkt**
  $\rightarrow$ Mischung aus nicht festgelegter Anzahl aus lexikalischen und phrasalen Kategorien
  $\rightarrow$ keine festgelegte Ordnung zwischen Kopf und Schwestern
- führt zu Problemen bei rekursiver Strukturdefinition (s. oben)

## X-Bar-Ebene

- Einführung **phrasaler Zwischenebene** (X') zwischen **Gesamtphrase (XP, maximale Projektion)** und **Kopf (X)**

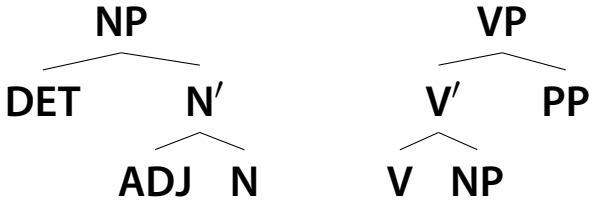


- Erlaubt die Differenzierung verschiedener Arten von *dependents* in Phrase durch Strukturposition

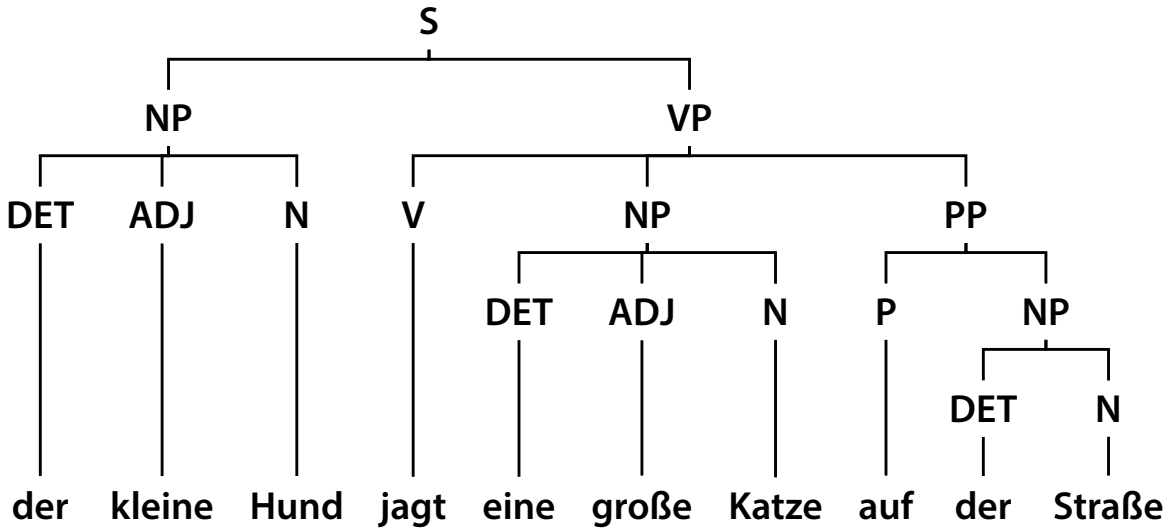


Abbildung 7: *zum Vergleich: nicht-beschränkte Phrasenstruktur (Einfacher Satz)*

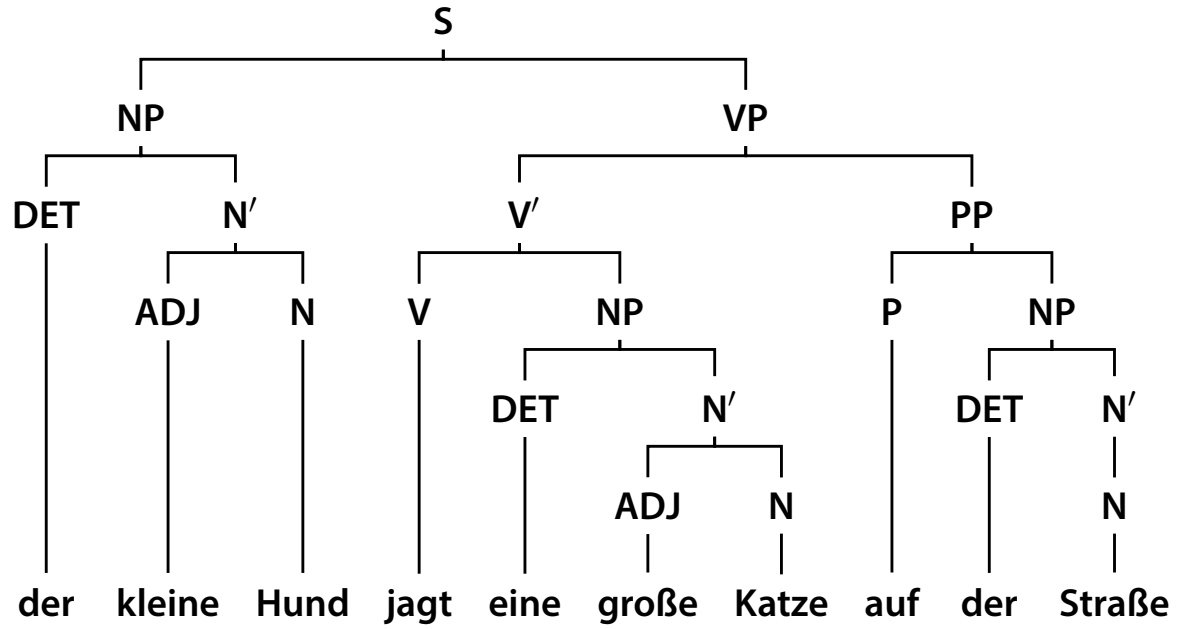


Abbildung 8: *Vorläufige X-Bar-Analyse NPs und VPs*

- **Verallgemeinerung der verbalen Argument-Adjunkt-Distinktion**
- **Komplement**: obligatorische (valenzgeforderte) Erweiterung
  $\rightarrow$ direkte Verbindung mit Phrasenkopf X, bildet X'-Phrase
  $\rightarrow$ enge Verbindung Komplement-Kopf
  $\rightarrow$ Deutsche NP: Genitiv-NP-Erweiterung oder von-PP
- **Adjunkt**: nicht-obligatorische Erweiterung, Anzahl nicht begrenzt
  $\rightarrow$ Verbindung mit X'-Konstituente, bildet wieder X'
  $\rightarrow$ Deutsche NP: Adjektiv-Attribut, PP-Attribut

- **Spezifizierer**: phrasenabschließende nicht-obligatorische Erweiterung
  $\rightarrow$ Verbindung mit X', Abschluß der XP-Phrase
  $\rightarrow$ in NP: Determinierer, Possessivpronomen oder Quantifizierer
  $\rightarrow$ verallgemeinert: als Strukturposition (XP $\rightarrow$ (SPEC) X') im Schema für Elemente mit bestimmten Eigenschaften
  $\rightarrow$ z. B. AUX als VP-Spezifizierer (s. unten)

- **Strukturpositionen im X-Bar-PSG-Schema:**

| | **X (Kopf)** | **X'** | **XP** |
|---|---|---|---|
| **Komplement** | Schwester | Tochter | |
| **Adjunkt** | | Schwester und Tochter | |
| **Spezifizierer** | | Schwester | Tochter |

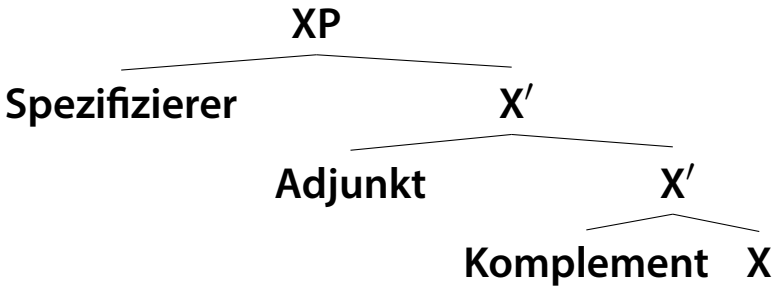

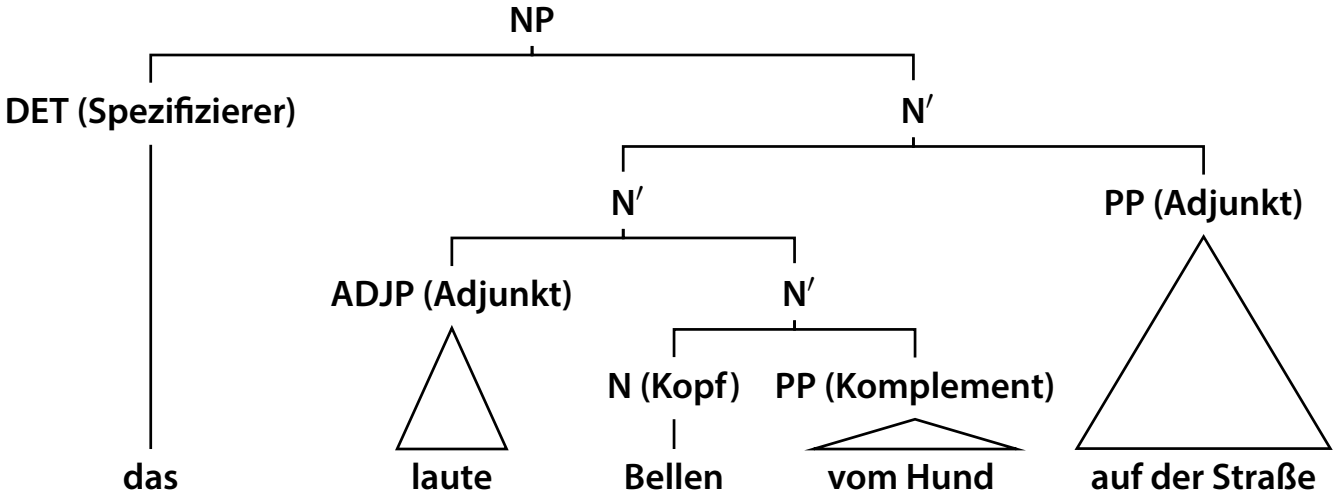


Abbildung 9: *X-Bar-Analyse NP mit Komplement-Adjunkt-Spezifizierer-Distinktion*

Auflistung 6: *PSG-Regeln X-Bar-Analyse NP*

```
1
2 #X-Bar-NP-Regeln:
3 NP → DET N'    #SPECIFIER
4 N' → ADJP N'    #ADJ-ADJUNKT
5 N' → N' PP      #PP-ADJUNKT
6 N' → N PP       #PP-KOMPLEMENT
7 N' → N
```

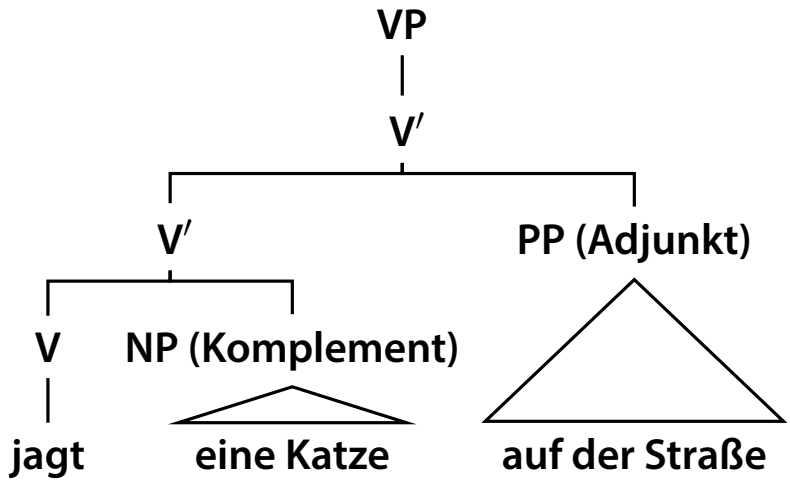


Abbildung 10: *X-Bar-Analyse VP mit Komplement-Adjunkt-Distinktion*

Auflistung 7: *PSG-Regeln X-Bar-Analyse VP*

```
1 #X-Bar-VP-Regeln:
2         VP → V'
3         V' → V' PP      #V'+ADJUNKT
4         V' → V NP       #KOPF+KOMPLEMENT
5         V' → V #KOPF (OHNE KOMPLEMENT)
```

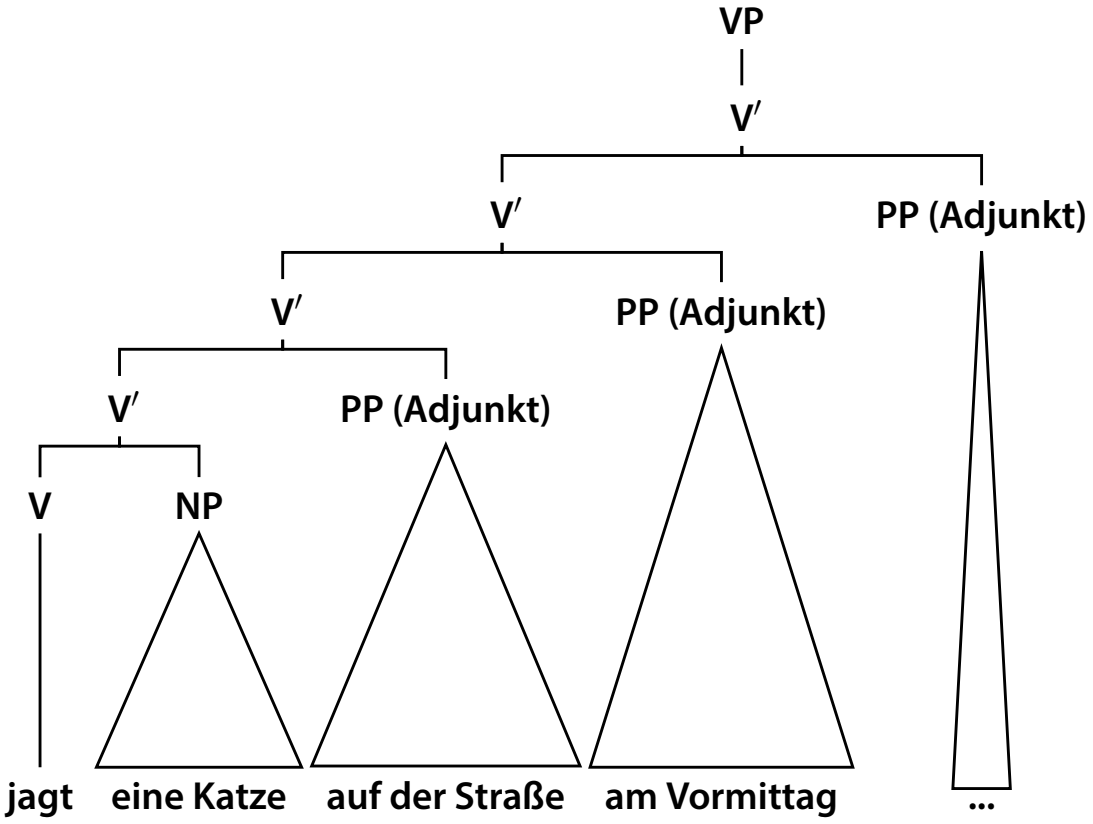


Abbildung 11: *X-Bar-Analyse VP mit rekursiver Adjunktionsregel*

## Allgemeines X-Bar-Schema

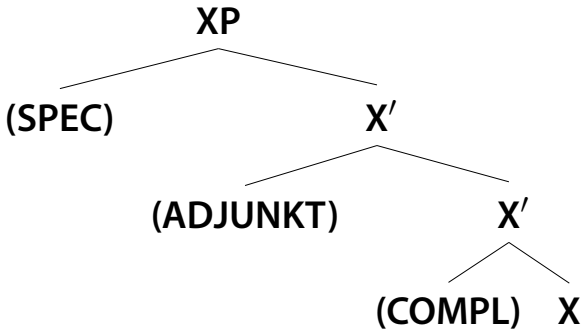


Abbildung 12: *Allgemeines X-Bar-Schema*

$XP \rightarrow (SPEC)\,, X'$

$X' \rightarrow (ADJUNKT)\,, X'$ (rekursive Regel)

$X' \rightarrow (COMPL)\,, X$

- X-Bar-Schema: **ohne implizierte lineare Struktur** (Wortstellung)
  → Einzelsprachliche Regeln

- **Links- vs. Rechtsverzweigung** (*left- vs rightbranching*)
  → Linksverzweigung: **head-final** (OV-Sprachen)
  → Rechtsverzweigung: **head-initial** (VO-Sprachen)
  → **Deutsche NP: Links- und Rechtsverzweigend**

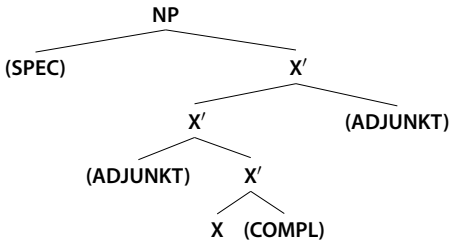

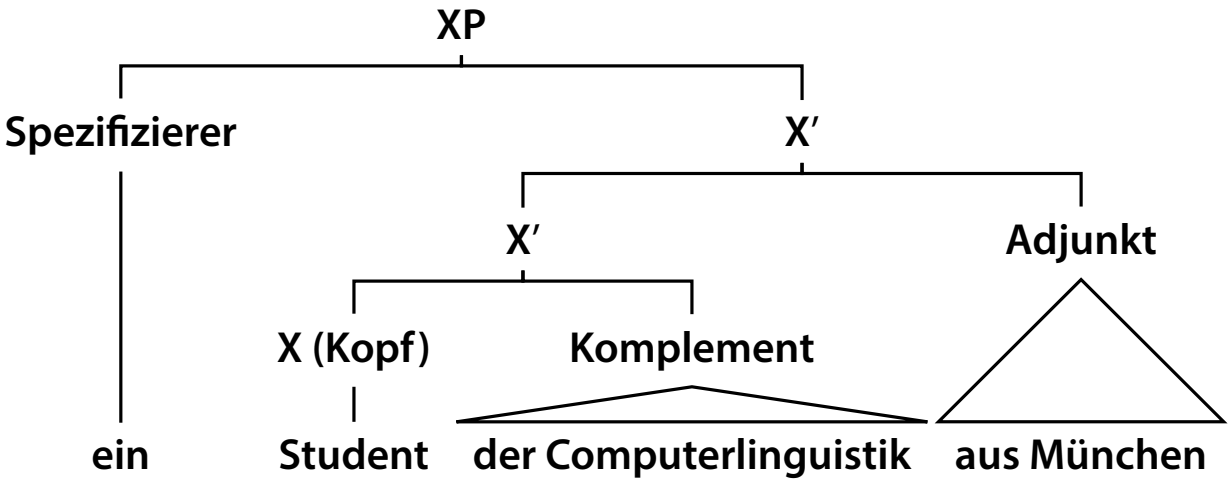


Abbildung 13: *allgemeine X-Bar-Analyse am Beispiel NP*

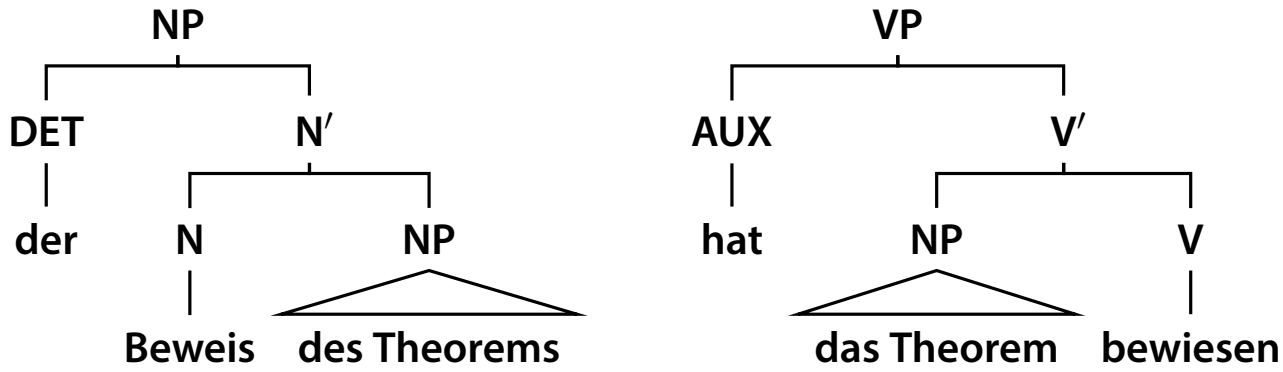


Abbildung 14: *Parallele X-Bar-Strukturanalyse für NP und VP (Spezifizierer und Komplement)*

## Anmerkung zu Auxiliarkonstruktionen

- **Auxiliare = Hilfsverben**
  $\rightarrow$ begleiten Verb (Träger lexikalischer Bedeutung)
  $\rightarrow$ Ausdruck von **grammatischen Merkmalen** (Tempus, Modus; Diathese; Flexionsmerkmale)
- Analyse ist stark **theorieabhängig** (Strukturposition)
- u. a. als Spezifizierer (s. o.)
- ebenso: Analyse als Verbgruppe (Verb + Auxiliare)
- ebenso: Eintrag in Subkategorisierungslexikon

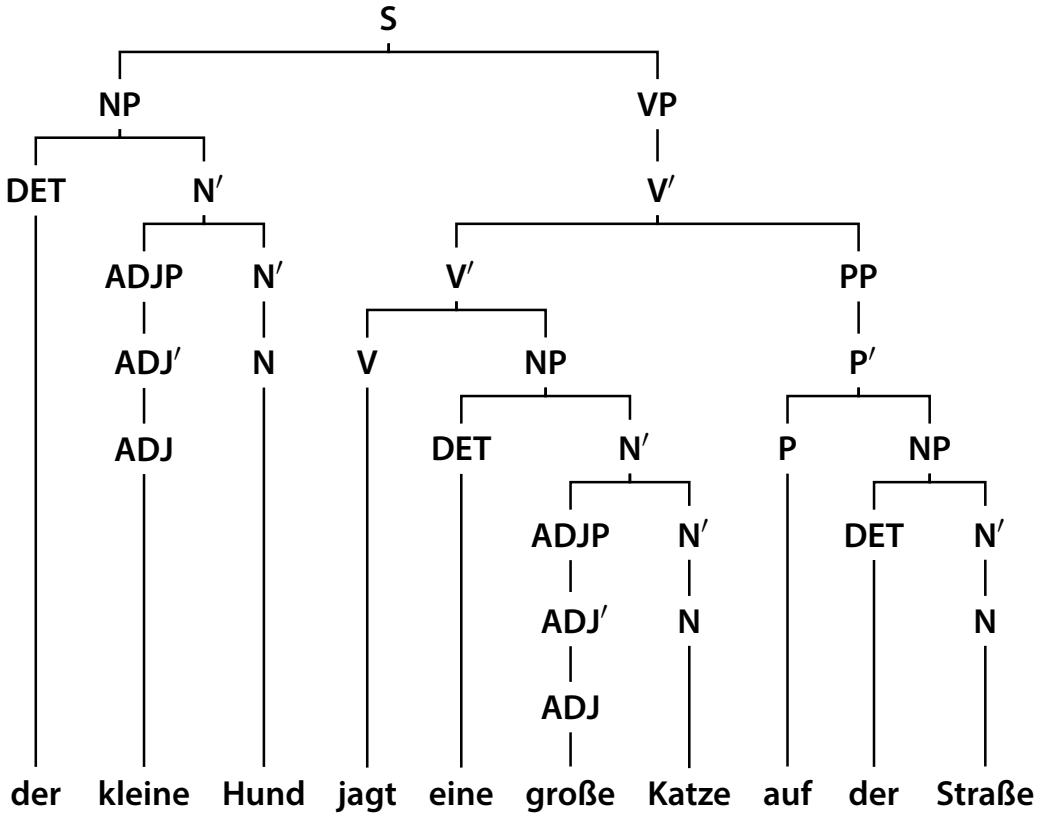


Abbildung 15: *Vollständige X-Bar-Analyse mit Komplement-Adjunkt-Spezifizierer-Distinktion*

# 4.4 Adäquatheit einer CFG als Syntaxmodell

- X-Bar-Phrasenstrukturgrammatiken schränken zwar durch ihre Strukturrestriktionen die Übergenerierung ein
- Übergenerierung bleibt aber weiter bestehen

## Gründe für Übergenerierung

- Nichtberücksichtigung von **Morphologie** (Kongruenz, Rektion):
  **der Mann sieht der Kind*
  **der Mann sieht das Kinder*

- Nichtberücksichtigung von **Subkategorisierung** (Verbvalenzrahmen)
  **der Hund starb die Katze*

## Lösungen

- **komplexere atomare Kategorien**
  → Problem: Regelvervielfachung
  → z.B. Numerus-Kongruenz NP: `SgN, PlN, SgDET, PlDET, SgNP, PlNP; SgNP → SgDET SgN, PlNP → PlDET PlN`
- **Merkmale in Lexikon**
  → Merkmalsstrukturen und Unifikation (Feststellung Merkmalskongruenz)
- Auswahl durch **probabilistisches Modell** (PCFG)
  → Übergenerierung erlauben
  → ungrammatische Sätze als unwahrscheinliche ausschließen

# 4.5 Treebanks und Grammatiken

- **Treebank** = Sammlung von per Hand annotierten Syntaxbäumen in bestimmtem Annotationsschema
- **Penn-Treebank**
  $\rightarrow$ relativ flache Struktur
  $\rightarrow$ arbeitet mit *traces* (Label: `NONE`) um *long-distance-dependencies* zu markieren
  $\rightarrow$ Schema verwendet im englischen Stanford-Parser-Modell

- **NEGRA-Korpus**
  → Grundlage deutsches Stanford-Parser-Modell
  → TIGER-Annotationsschema basiert auf NEGRA-Schema
  → noch flacher als Penn-Treebank

- ***grammar induction***
  → Treebanks als **implizite Grammatik**
  → **CFG-Regeln können aus Treebank-Korpus gewonnen werden**

- `tgrep`: Programm zur Suche in Syntaxbäumen (s. u.)

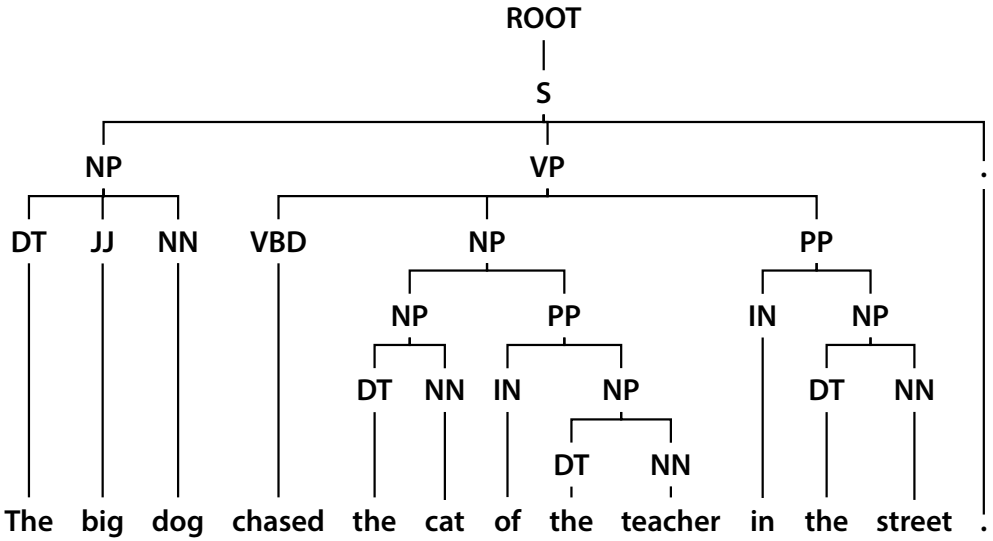


Abbildung 16: *Beispiel-Parse Stanford-Parser*

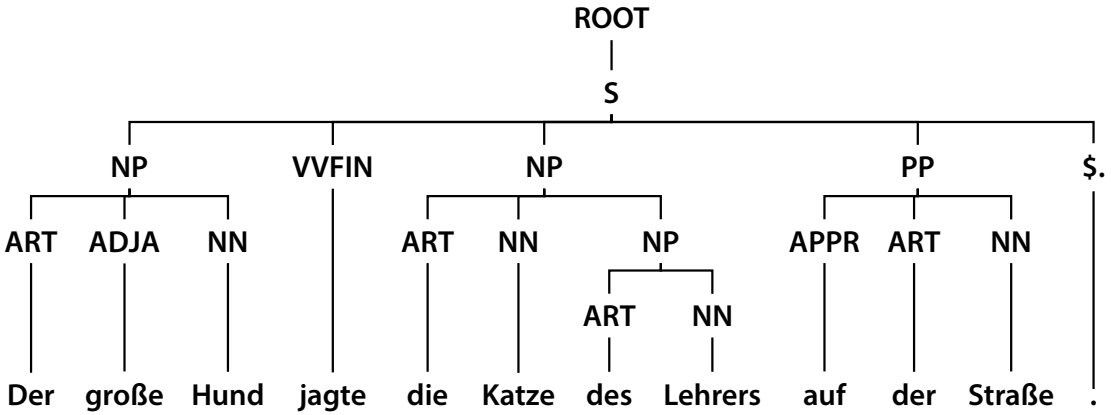


Abbildung 17: *Beispiel-Parse Stanford-Parser (Deutsches Modell)*

Auflistung 8: *NLTK: Parsing mit Stanford-Parser; verschiedene Ausgabeformate*

```
1  http://www.nltk.org/howto/tree.html
2
3  from nltk.parse.stanford import StanfordParser
4  jar = "stanford-corenlp-3.8.0.jar"
5  model = "stanford-corenlp-3.8.0-models.jar"
6  parser=StanfordParser(jar,model,model_path="edu/stanf
7
8  tree_list = list(parser.raw_parse('The big dog
     chased the cat of the teacher in the
     street.'))
9  tree = tree_list[0]
10
11
12
13
```

```
14 print(tree)
15 # (ROOT
16 #   (S
17 #     (NP (DT The) (JJ big) (NN dog))
18 #     (VP
19 #       (VBD chased)
20 #       (NP
21 #         (NP (DT the) (NN cat))
22 #         (PP (IN of) (NP (DT the) (NN
   teacher))))
23 #       (PP (IN in) (NP (DT the) (NN street))))
24 #     (. .)))
25
26
27
28
```

```
29 print(tree.pformat_latex_qtree())
30 # \Tree [.ROOT
31 #           [.S
32 #             [.NP [.DT The ] [.JJ big ] [.NN
     dog ] ]
33 #             [.VP
34 #               [.VBD chased ]
35 #               [.NP
36 #                 [.NP [.DT the ] [.NN cat ] ]
37 #                 [.PP [.IN of ] [.NP [.DT the ]
     [.NN teacher ] ] ] ]
38 #               [.PP [.IN in ] [.NP [.DT the ]
     [.NN street ] ] ] ]
39 #             [.. . ] ] ]
40
41
```

```
42 tree.label()
43 #'ROOT'
44
45 print(tree[0,0])
46 #(NP (DT The) (JJ big) (NN dog))
47
48 print(tree[0,2])
49 #(. .)
50
51 print(tree[0,1,2])
52 #(PP (IN in) (NP (DT the) (NN street)))
53
54 print(tree[0,0,0]); print(tree[0,0,1])
55 #(DT The)
56 #(JJ big)
```

Auflistung 9: *nltk_tgrep*

```
#https://pypi.python.org/pypi/nltk_tgrep/
sudo pip install nltk_tgrep

from nltk.tree import ParentedTree
import nltk_tgrep
tree = ParentedTree.fromstring('(S (NP (DT
  the) (JJ big) (NN dog)) (VP bit) (NP (DT a)
  (NN cat)))')
nltk_tgrep.tgrep_nodes(tree, 'NN')
#[ParentedTree('NN', ['dog']),
  ParentedTree('NN', ['cat'])]
nltk_tgrep.tgrep_positions(tree, 'NN')
#[(0, 2), (2, 1)]
nltk_tgrep.tgrep_nodes(tree, 'DT $ JJ')
#[ParentedTree('DT', ['the'])]
```