Übersicht

12 Statistische Syntaxmodelle

12.1 Induzierte PCFG-Modelle

12.1.1 *grammar induction* aus Treebank
12.1.2 Normalisierung und Evaluation
12.1.3 PCFGs mit abgeschwächten Unabhängigkeitsannahmen
12.1.4 Lexikalisierte PCFGs
12.1.5 *history-based* PCFGs

12.2 Dependenzbasierte Modelle

12.2.1 Dependenzgrammatiken
12.2.2 Übergangsbasiertes Dependency-Parsing
12.2.3 Graphbasiertes Dependency-Parsing
12.2.4 *Dependency-Treebanks*

12 Statistische Syntaxmodelle

12.1 Induzierte PCFG-Modelle

- **Grammatikentwicklung** (***grammar writing***) ist **aufwendig**
  $\rightarrow$ Grammatiken mit **von Experten geschriebenen Regeln** mit hoher ***Abdeckung***

- Alternative: **Induktion von Grammatikregeln aus Korpora**
  $\rightarrow$ **empirisches Syntaxmodell**
  $\rightarrow$ Berücksichtigung **relativer Häufigkeiten der Regeln** $\Rightarrow$ **PCFG**
  $\rightarrow$ als **statistisches Modell**: direkte Verwendung zur **Disambiguierung**

12.1.1 *grammar induction* aus Treebank

- **Treebank** als **implizite Grammatik**
  $\rightarrow$ jeder **Teilbaum** der Tiefe 1 als **implizite CFG-Regel**
  $\rightarrow$ **Expansion eines Nonterminals**
- **Extraktion von CFG-Regeln** aus den Ableitungen der Treebank
- Frequenzbestimmung der Regeln und Berechnung **Regelwahrscheinlichkeiten** über **relative Häufigkeiten** ($\Rightarrow$ PCFG)
  $\rightarrow$ **Gewichtung** insbesondere **bei induzierter Grammatik notwendig**: viele Regeln $\Rightarrow$ hohe Ambiguität
- Anwendung von **Smoothing und Normalisierung**

- **Form der induzierten Grammatik** hängt stark vom **Annotationsschema** der dem Training des Modells zugrundeliegenden Treebank ab:
  - **flache Grammatik = viele Regel-types:**
    $\rightarrow$ Penn-Treebank: 1 Mill. *Worttokens*, 1 Mill. *nicht-lexikalische Regel-tokens*, 17.500 *Regel-types*
    $\rightarrow$ z. B. jedes PP-Adjunkt mit eigener Regel:
    $VP \rightarrow V\ PP$, $VP \rightarrow V\ PP\ PP$, $VP \rightarrow V\ PP\ PP\ PP$ usw.
  - **tiefere Bäume: mehr Nonterminale, weniger Regel-types**:
    $\rightarrow$ z. B. X-Bar:
    $VP \rightarrow V'$, $V' \rightarrow V'\ PP$, $V' \rightarrow V$

Auflistung 1: *Ableitungsbaum in Penn-Treebank*

```
1  from nltk.corpus import treebank
2  t=nltk.corpus.treebank.parsed_sents('wsj_0003.mrg')[4]
3  print(t)
4  # (S
5  #   (NP-SBJ (DT A) (NNP Lorillard) (NN
       spokewoman))
6  #   (VP
7  #     (VBD said)
8  #     (, ,)
9  #     (`` ``)
10 #     (S
11 #       (NP-SBJ (DT This))
12 #       (VP (VBZ is) (NP-PRD (DT an) (JJ old)
       (NN story)))))
13 #   (. .))
```

Auflistung 2: *NLTK: Extraktion von Grammatikregeln aus Treebank (`nltk.induce_pcfg`)*

```
1  ##http://www.nltk.org/book/ch08-extras.html
2  ##http://www.nltk.org/_modules/nltk/grammar.html#indu
3
4  import nltk
5  from nltk.corpus import treebank
6
7  productions = []
8  S = nltk.Nonterminal('S')
9  for tree in
     nltk.corpus.treebank.parsed_sents('wsj_0003.mrg')[4]
10     productions += tree.productions()
11
12 grammar = nltk.induce_pcfg(S, productions)
13 for production in grammar.productions():
14     print(production)
```

```
NP-SBJ → DT NNP NN [0.5]
DT → 'A' [0.333333]
NNP → 'Lorillard' [1.0]
NN → 'spokewoman' [0.5]
VP → VBD , `` S [0.5]
VBD → 'said' [1.0]
, → ',' [1.0]
`` → '``' [1.0]
S → NP-SBJ VP [1.0]
NP-SBJ → DT [0.5]
DT → 'This' [0.333333]
VP → VBZ NP-PRD [0.5]
VBZ → 'is' [1.0]
NP-PRD → DT JJ NN [1.0]
DT → 'an' [0.333333]
JJ → 'old' [1.0]
NN → 'story' [0.5]
. → '.' [1.0]
```

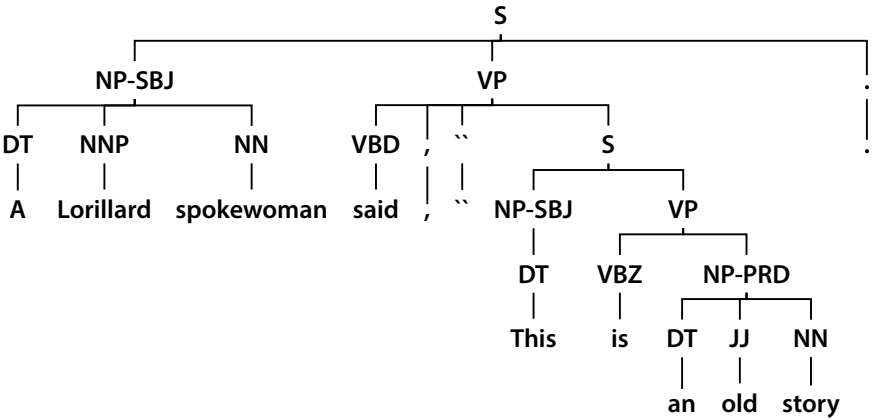

Stanford-PCFG-Parser:

- basiert auf **aus Treebanks extrahierten PCFG**-Modellen

  → `https://nlp.stanford.edu/software/lex-parser.shtml`

- Trainingskorpus des englischen Modells (`englishPCFG.ser.gz`): **Penn Treebank**

- Trainingskorpus des deutschen Modells (`germanPCFG.ser.gz`): **NEGRA Korpus**

12.1.2 Normalisierung und Evaluation

Normalisierung

- **Chomsky-Normalform** (CNF)

  $\rightarrow$ Einschränkung der Form von CFG-Regeln:

  $\Rightarrow$ **RHS: 2 Nichtterminale oder 1 Terminal:** $A \rightarrow B\ C$**,** $A \rightarrow a$

  $\rightarrow$ **Binärbäume** (bis Präterminalknoten, dort: unäre Bäume)

  $\rightarrow$ **jede CFG kann in CNF umgewandelt** werden:

  $A \rightarrow B\ C\ D \Rightarrow A \rightarrow B\ X, X \rightarrow C\ D$ (***Right-Factored***)

  $A \rightarrow B\ C\ D \Rightarrow A \rightarrow X\ D, X \rightarrow B\ C$ (***Left-Factored***)

Original:

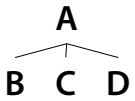

Right-Factored:

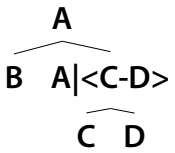

Left-Factored:

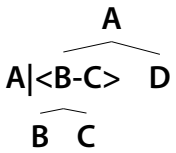

- **Anwendung Chomsky-Normalform:**
  - notwendig für **CYK-Chart-Parsing**
  - zur **Reduktion von extrahierten Grammatikregeln** aus flach annotiertem Korpus:
    * $VP \rightarrow V\ PP$
      $VP \rightarrow V\ PP\ PP$
      $VP \rightarrow V\ PP\ PP\ PP$ usw.
    * mit ***Chomsky-adjunction*** ($A \rightarrow A\ B$):
      $VP \rightarrow V\ PP$
      $VP \rightarrow VP\ PP$

- ***Parent Annotation***

  → Kategorie des **Mutterknoten in Kategoriensymbol** aufnehmen

  → Modellierung von **Kontext**; s. unten: *history-based PCFGs*

  → ergibt anderes PCFG-Modell: **mehr Nichtterminale, andere Gewichtung**

Original:

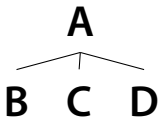

Parent Annotation (+CNF):

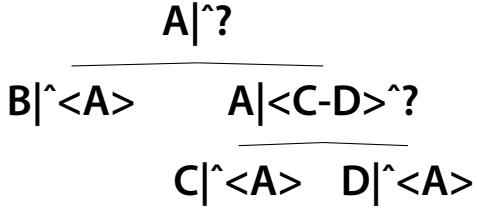

Auflistung 3: *NLTK: Transformationen*

```
1  ##http://www.nltk.org/_modules/nltk/treetransforms.ht
2  from nltk.draw.tree import draw_trees
3  from nltk import tree, treetransforms
4  from copy import deepcopy
5  sentence = """(S (NP-SBJ (NP (QP (IN at) (JJS
     least) (CD nine) (NNS tenths)) )
6      (PP (IN of) (NP (DT the) (NNS students)
         ))) (VP (VBD passed)))"""
7  t = tree.Tree.fromstring(sentence,
     remove_empty_top_bracketing=True)
8
9  # collapse subtrees with only one child
10 collapsedTree = deepcopy(t)
11 treetransforms.collapse_unary(collapsedTree,
     collapsePOS=False)
```

```
12 # convert the tree to CNF
13 cnfTree = deepcopy(collapsedTree)
14 treetransforms.chomsky_normal_form(cnfTree)
15
16 # convert the tree to CNF with parent
     annotation (one level)
17 parentTree = deepcopy(collapsedTree)
18 treetransforms.chomsky_normal_form(parentTree,
     vertMarkov=1)
19
20 # convert the tree to CNF with parent
     annotation (two levels)
21 grandparentTree = deepcopy(collapsedTree)
22 treetransforms.chomsky_normal_form(grandparentTree,
     vertMarkov=2)
```

- **Original:**

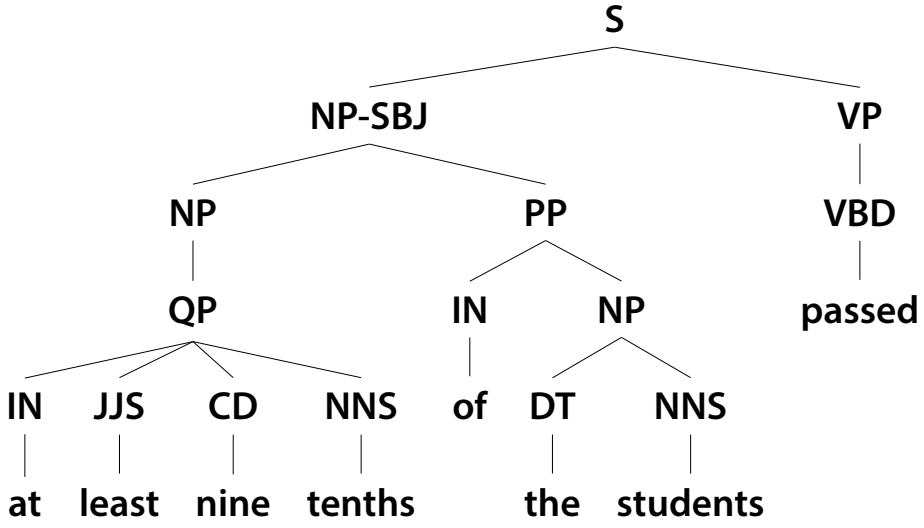
S
NP-SBJ
VP
NP
PP
VBD
QP
IN
NP
passed
IN
JJS
CD
NNS
of
DT
NNS
at
least
nine
tenths
the
students

- **ohne unäre Teilbäume = *unary reduction* (`collapsePOS=False`):**

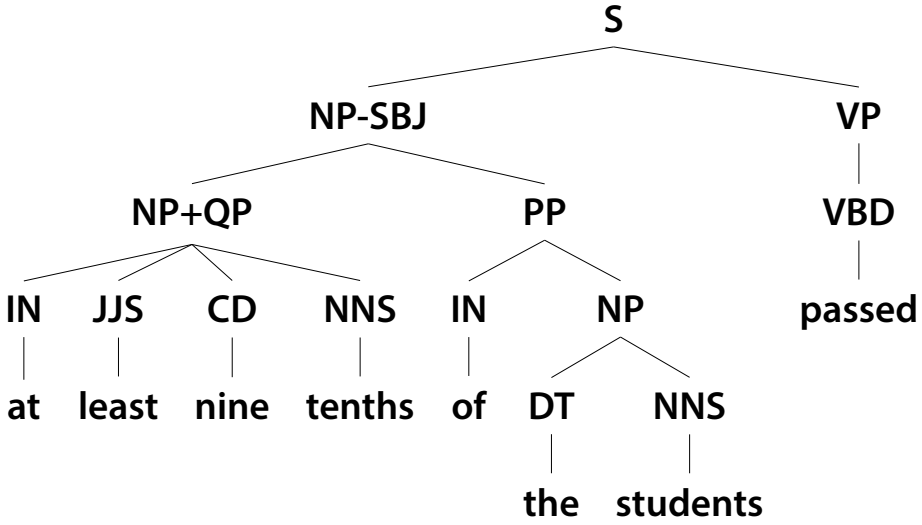

- **Chomsky-Normal-Form (mit *unary reduction*):**

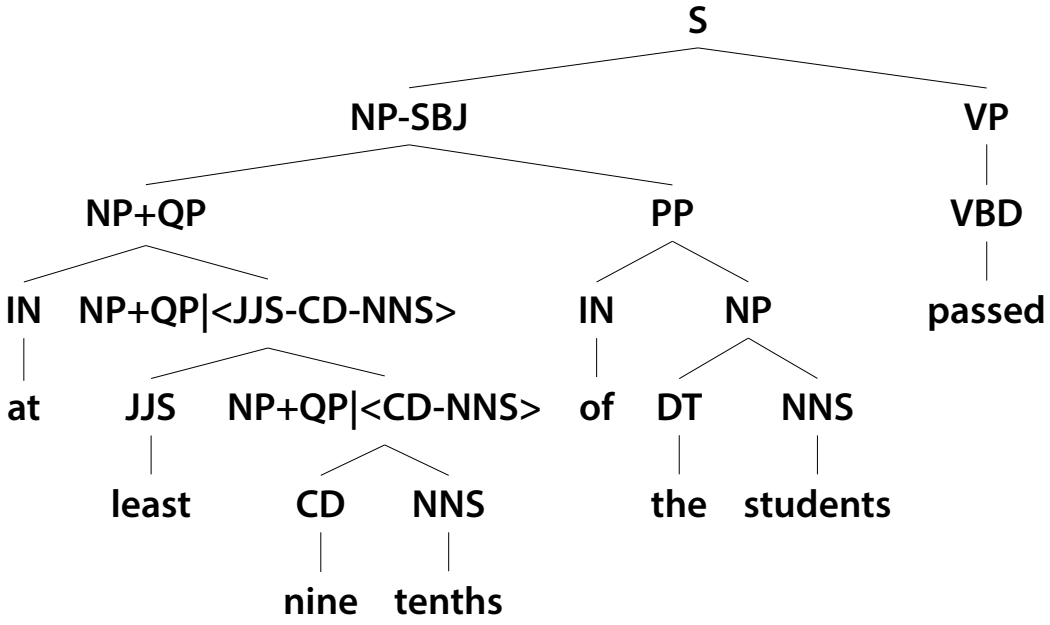

- **Parent Annotation (mit *unary reduction* und CNF):**

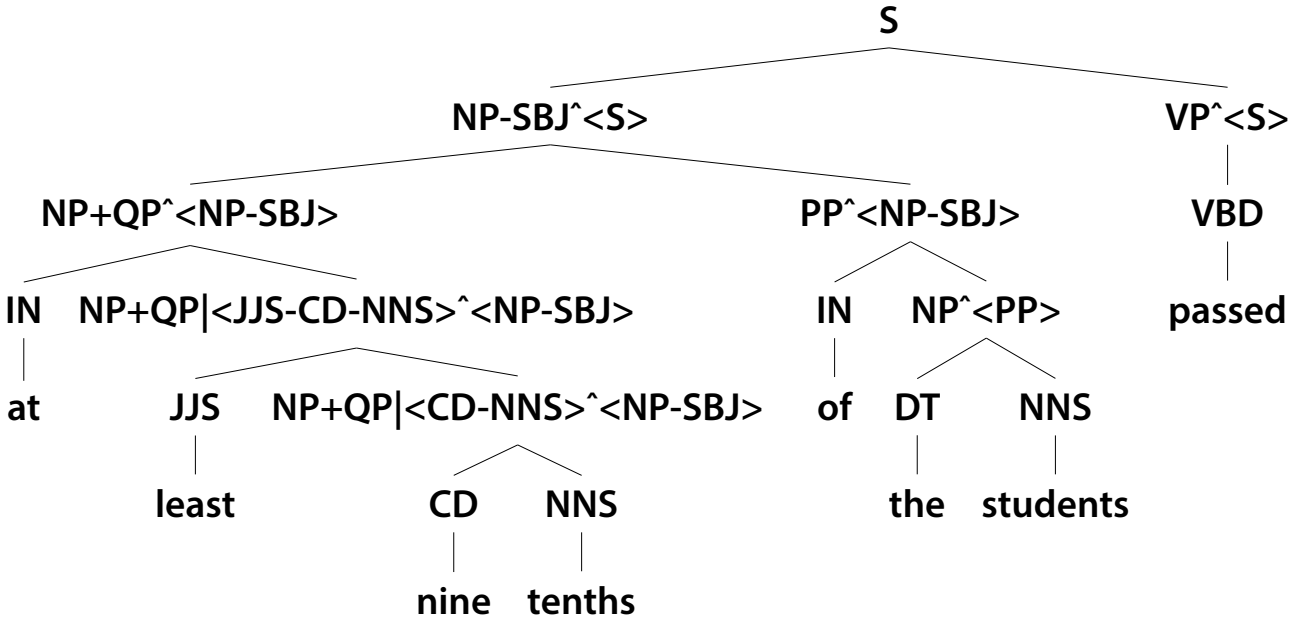

- **Parent Annotation mit Großvaterkategorie:**

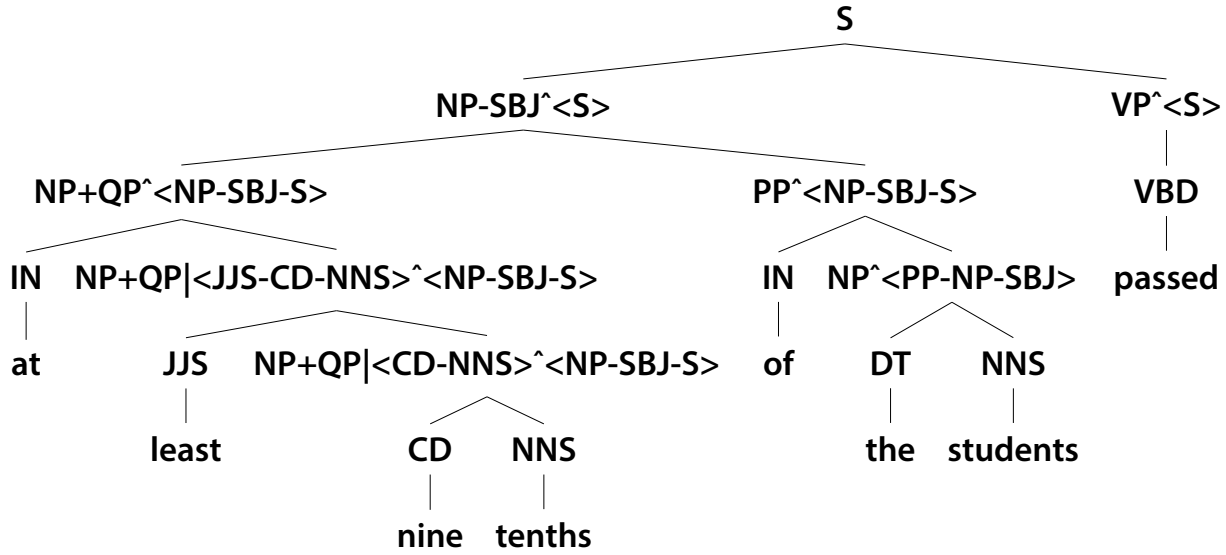

Evaluation

- Messen der **Güte von Grammatikmodellen/Parsern** durch Parsen von Sätzen einer **Testmenge**
  $\rightarrow$ **Teilmenge einer hand-annotierten Treebank** = *gold-standard*-Ableitungen, z. B. von Penn-Treebank
- **PARSEVAL-Maße (Black et al. 1991)**: Übereinstimmung von Konstituenten in den Ableitungen von **geparsten Daten (Ableitungshypothese H)** mit denen der **Test-Daten (Referenz-Ableitung R)**
  $\rightarrow$ Konstituente ist **korrekt** wenn Übereinstimmung in **Nichtterminal-Symbol** und **Spanne (gleicher Start- und Endpunkt)**

- **Recall** $= \frac{(\text{Anzahl von korrekten Konstituenten in Hypothese})}{(\text{Anzahl von Konstituenten in Referenz-Ableitung})}$
- **Precision** $= \frac{(\text{Anzahl von korrekten Konstituenten in Hypothese})}{(\text{Anzahl von allen Konstituenten in Hypothese})}$

  $\rightarrow$ Hypothese: (A) (B C D)

  $\rightarrow$ Referenz: (A) (B) (C) (D)

  $\rightarrow$ Recall = 1/4; Precision: 1/2

- **cross-brackets**: Anzahl an Konstituenten mit **((A B) C)** in Ableitungshypothese aber **(A (B C))** in Referenz-Ableitung

- **moderne Parser**: ca. **90% Precision und Recall**, ca. **1% cross-brackets**-Konstituenten (trainiert und getestet mit Penn-Treebank)

12.1.3 PCFGs mit abgeschwächten Unabhängigkeitsannahmen

2 Unabhängigkeitsannahmen von PCFGs

- **Annahme Unabhängigkeit von lexikalischem Material**
  $\rightarrow$ Wahrscheinlichkeiten von Teilbäumen sind unabhängig von Terminalen
- **Annahme Unabhängigkeit von Kontext**
  $\rightarrow$ Wahrscheinlichkeiten von Teilbäumen sind unabhängig von Elternknoten
- **Zurücknahme von Unabhängigkeitsannahmen:**
  $\Rightarrow$ **beschreibungsadäquatere Syntaxmodelle**
  $\Rightarrow$ Berücksichtigung **linguistischer Abhängigkeiten**

- Berücksichtigung **lexikalischer Abhängigkeiten:**
  $\Rightarrow$ ***lexikalisierte PCFGs***
  $\Rightarrow$ Auflösung **lexikalischer Ambiguität**

- Berücksichtigung **struktureller Abhängigkeiten zwischen Regeln:**
  $\Rightarrow$ ***history-based PCFGs***
  $\Rightarrow$ Auflösung **kontextabhängiger struktureller Ambiguität**

12.1.4 Lexikalisierte PCFGs

Lexikalisierte PCFGs

- PCFGs basierend auf einfachen CFG-Regeln:
  $\Rightarrow$ nur **strukturelle Disambiguierung**
- Probleme mit **lexikalisch determinierter Ambiguität**, z. B. bei **Subkategorisierung** oder **PP-Attachment**
- **statisches Modellierung lexikalischer Abhängigkeiten**
- bekannter lexikalisierter Parser: Collins Parser (Collins, 1999)

Vorgehen Lexikalisierung

- **buttom-up-Annotation** nichtterminaler Kategorien **mit lexikalischer Information** (Kopf-Perkolation): `VP(kennt)`
- auch Annotation mit **Part-of-Speech-Tag** möglich: `NP(er, PRON)`

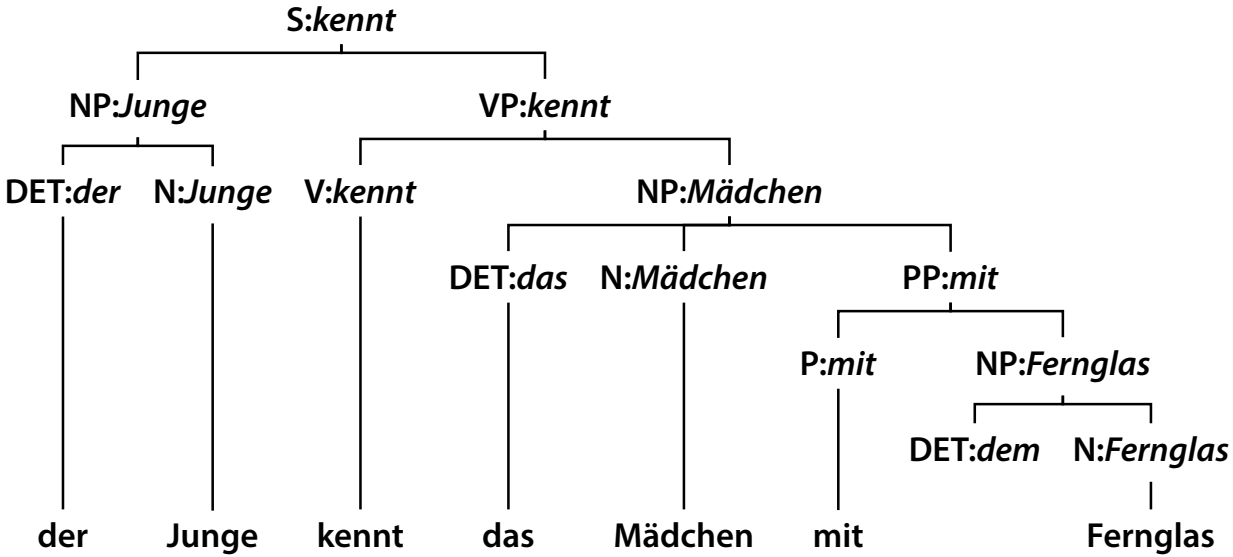

Abbildung 1: *Beispiel für lexikalisierte Phrasenstruktur*

PP-Attachment

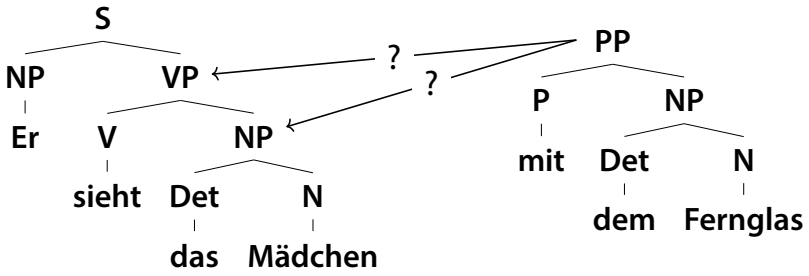

- strukturelle Ambiguität:
  NP- oder VP-Anbindung?
  $\Rightarrow$ 2 strukturelle Lesarten:
  $\rightarrow$ (VP V (NP N PP))
  $\rightarrow$ (VP V (NP N) PP)

- **unlexikalisierte PCFG**: immer Entscheidung für eine Variante
  $\rightarrow$ z. B. **englisches Trainigskorpus: NP-Attachment-Frequenz etwas höher**

- häufig: Anbindung lexikalisch konditioniert (**lexikalische Abhängigkeit**):
  - **Bevorzugung von VP-Anbindung**: *Sie stellt die Blumen ins Wasser.*
    $\rightarrow$ engere Verbindung von *stellt* mit *ins* als zwischen *Blumen* und *ins*
  - **Bevorzugung von NP-Anbindung**: *Der Junge kennt das Mädchen mit dem Fernglas.*
    $\rightarrow$ engere Verbindung von *Mädchen* mit *mit* als zwischen *kennt* und *mit*

Subkategorisierung

- **statisches Modellierung Subkategorisierung** statt regelbasiert über Subkategorisierungsrahmen
- **transitive Verben:** hohe Wahrscheinlichkeit `P(VP → V NP)` → `P(V NP | VP, sehen) > P (V | VP, sehen)`
- **intransitive Verben:** hohe Wahrscheinlichkeit `P(VP → V)` → `P(V | VP, laufen) > P (V NP | VP, laufen)`

Probleme lexikalisierter PCFGs

- **Modell** wird **sehr groß**
  $\rightarrow$ Grund: **viel mehr Ereignisse** durch lexikalisierte Regeln
  $\rightarrow$ **Regelvervielfachung:**
  VP(sieht) $\rightarrow$ *V(sieht) NP(Mädchen)*
  VP(kennt) $\rightarrow$ *V(kennt) NP(Mädchen)*

- **umfangreiche Trainingsdaten** notwendig für Parameterabschätzung des Modells

- **neue Abschätzung** für Regelwahrscheinlichkeiten notwendig
  $\rightarrow$ **MLE-Abschätzung** über $P(\alpha \rightarrow \beta|\alpha) = \frac{count(\alpha \rightarrow \beta)}{count(\alpha)}$ ist **zu spezifisch**
  $\rightarrow$ **geht meistens gegen 0,** da **nur sehr wenige Instanzen** der lexikalisierten Regeln in Trainingskorpus vorhanden

- ***sparse data***-Problem aufgrund von in Trainingsdaten **ungesehenen Wörtern/Instanzen** ($\Rightarrow$ keine Regel vorhanden)
  $\rightarrow$ Lösung: **Backoff** = **Verzicht auf Lexikalisierung** bei **unbekanntem** lexikalischen Kopf

- dazu notwendig: **Smoothing** (Glättung der Regelwahrscheinlichkeiten)
  $\rightarrow$ **Reservierung von Wahrscheinlichkeitsmasse** für Regeln bei Backoff bei ungesehenen Köpfen
  $\rightarrow$ Zuordnung von Wahrscheinlichkeit für Regel mit **ungesehenem Kopf**
  $\rightarrow$ z. B. **Laplace-Smoothing**: zu jeder Häufigkeit im Korpus: **Wert addieren** (1 = **Add-One-Smoothing**) $\Rightarrow$ Backoff-Regel: $P > 0$

- **Backoff bei Collins Parser**: unbekannte Köpfe aus Testmenge und aus Trainingsmenge mit Frequenz < 6 werden mit `UNKNOWN` ersetzt

12.1.5 *history-based* PCFGs

history-based PCFGs

- Berücksichtigung **Abhängigkeit Expansion von Kontext**
  → **Regelauswahl abhängig von vorheriger Regelauswahl**
  → Wahrscheinlichkeit einer Expansion ist abhängig von der **Position im Strukturbaum**
- z. B. **unterschiedliche Expansionswahrscheinlichkeiten für NPs** in Subjekt- bzw. Objektposition
  → **Subjekt-NP** (S-dominiert) erweitert **wahrscheinlicher zu Pronomen als Objekt-NP** (VP-dominiert)
  → `P(NP→PRON|S) > P(NP→PRON|VP)`
  → `P(PRON|NP,S) > P(PRON|NP,VP)`

- Grund = **Informationsstruktur**
  → **Subjekt** typischerweise Topik = **bekannte Information**, die durch Pronomen ausgedrückt wird

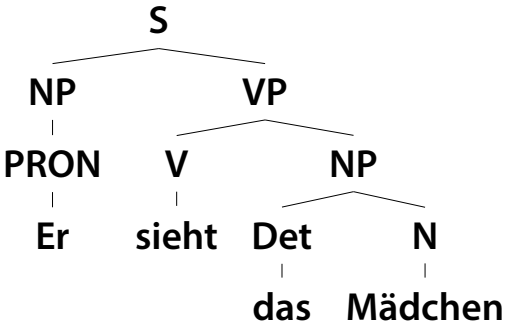

	Pronomen	Nicht-Pronomen
Subjekt	91%	9%
Objekt	34%	66%

Abbildung 2: *Verteilung der Form von Subjekt und Objekt in englischem Korpus (nach Francis et al., 1999, vgl. SLP2, 502)*

- **erwünschte Regelgewichtung Subjekt (S-dominiert):**
  NP $\rightarrow$ PRON **0.91**
  NP $\rightarrow$ DET N 0.09
- **erwünschte Regelgewichtung Objekt (VP-dominiert):**
  NP $\rightarrow$ PRON 0.34
  NP $\rightarrow$ DET N **0.66**
- **normale PCFG** (keine Differenzierung, Daten aus Korpus):
  NP $\rightarrow$ PRON **0.25**
  NP $\rightarrow$ DET N **0.28**

- **Lösung: Splitting NP-Kategoriensymbol (*parent annotation*):**

  NP^S $\rightarrow$ PRON 0.91

  NP^S $\rightarrow$ DET N 0.09

  NP^VP $\rightarrow$ PRON 0.34

  NP^VP $\rightarrow$ DET N 0.66

Vorgehen

- **Annotation** nichtterminaler Kategorien **mit Kategorie des Mutterknotens** (= *history*)
  $\Rightarrow$ ***parent annotation***
  $\rightarrow$ Subjekt-NP: `NP^S`
  $\rightarrow$ Objekt-NP: `NP^VP`
  $\rightarrow$ "*Splitting* von Nicht-Terminalen"

Subjekt-NP:

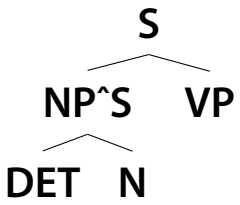

Objekt-NP:

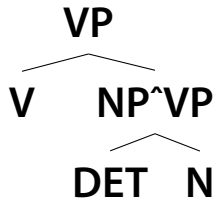

Probleme von *history-based* PCFGs

- **ähnlich** wie bei **Lexikalisierung**, aber weniger stark ausgeprägte Regelvervielfachung durch *parent annotation*
  $\rightarrow$ *sparse data*: **unbekannte Vorgängerkategorie**
- kleinere Regelmenge durch **selektive *parent annotation***
  $\rightarrow$ **nur** Splitten, wenn ***accuracy*** **erhöht** wird

12.2 Dependenzbasierte Modelle

12.2.1 Dependenzgrammatiken

- in Computerlinguistik sind traditionell **Konstituenten-basierte Formalismen dominant** (Chomsky-Tradition Generativer Grammatik)
- **Dependenzbasierte Syntaxmodelle** werden immer wichtiger
- statt Konstituentenstruktur (= Regeln der Zusammensetzung syntaktischer Einheiten):
  $\Rightarrow$ **Modellierung Syntax über binäre Abhängigkeitsrelationen zwischen Wörtern im Satz (grammatische Relationen)**

- **Dependenzgraph** $G = (V, A)$**:**
  $\rightarrow$ Menge von Knoten ($V = Vertices$)
  $\rightarrow$ Menge von (gelabelten) gerichteten Kanten ($A = Arcs$)

- **Induktion von Dependenz-Parsing-Modellen aus Treebank möglich**
  $\rightarrow$ **Dependency-Treebank** kann handannotiert sein oder abgeleitet aus PSG-Treebank

- Dependenzanalysen können auch **sekundär aus Analysen mit konstituentenbasierten Parsern** erzeugt werden
  $\rightarrow$ z. B. Stanford-PCFG-Parser

Vorteile von Dependenzmodellen

- **Relationale Informationen direkt** vorhanden statt indirekt über Position in Strukturbaum
  $\rightarrow$ Verwendung z. B. für **Informationsextraktion**
- **Wortgrammatik** = direkte Modellierung von Relation zwischen Wörtern
  $\rightarrow$ **keine Lexikalisierung notwendig**

- **Dependenzgrammatik als Wortgrammatik**
  $\Rightarrow$ **reduziert *sparse data*-Problem bei Parameterabschätzung**
  $\rightarrow$ bei induziertem **PCFG-Modell mit flacher Struktur** treten **häufig ungesehene Bäume** auf, z. B.: `VP` $\rightarrow$ `V NP PP PP`
  $\Rightarrow$ nur Backoff zu '`UNKNOWN`'-Wahrscheinlichkeit möglich
  $\rightarrow$ **Dependenzgrammatik teilt Struktur auf in binäre Relationen** zwischen den Wörtern
  $\rightarrow$ jede *head-dependent*-Relation wird **separat gewichtet**
  $\rightarrow$ **Beispiel:** `VP` $\rightarrow$ `V NP PP` und `VP` $\rightarrow$ `V PP PP` in Treebank
  $\Rightarrow$ man kann **aus den gesehenen *head-dependent*-Beziehungen** (`V` $\Rightarrow$ `N`, `V` $\Rightarrow$ `P`, `V` $\Rightarrow$ `P`) die von `VP` $\rightarrow$ `V NP PP PP` **ohne Backoff abschätzen**

wichtige Anwendungsgebiete von Dependenzanalysen

- **Informationsextraktion**
  $\rightarrow$ *relation extraction* (s. Übung)
- **Semantisches Parsing**
- **Question Answering**

Regelbasierte Dependenzgrammatik-Modelle

- **von Experten erstellte** Dependenzgrammatiken
- wichtige Dependengrammatik-Formalismen:
  Bedeutung-Text-Modell (I.A. Meľčuk), **Word Grammar**, **Link Grammar**, **Constraint-Grammar**

- Modellierung über (lexikalisierte) **kontextfreie Grammatiken**
  $\rightarrow$ nur projektive Strukturen möglich
- Modellierung über **Constraint-basierte Dependenzgrammatiken**
  $\rightarrow$ **Angabe von Wohlgeformtheitsbedingungen**
  $\rightarrow$ **Entfernung von Constraint-verletzenden Graphen** im Parsing
- **Constraint-Parsing**: Verarbeitung von **nicht-projektiven Strukturen**

Nichtprojektivität

- **projektive Struktur:** alle Kanten sind **projektiv, d. h. es gibt einen Pfad vom Kopf der Relation zu jedem Wort zwischen Kopf und Dependent**
- **nicht-projektive Struktur: Überschneidung von Kanten**
  $\rightarrow$ z. B.: Dependent eines Wortes folgt nach dessen Kopf

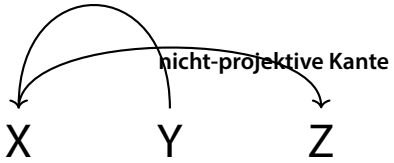

- bei **Ableitung Dependenzgrammatik** von PSG-Treebanks durch *head-finding-rules* ergeben sich **automatisch projektive** Strukturen
- **linguistisch: nicht-projektive Strukturen** entstehen durch **diskontinuierliche Elemente**
  $\rightarrow$ **freie Wortstellung und *long distance dependencies***

- Dependenzgrammatiken sind **besser** als Konstituentengrammatiken **geeignet**, **diskontinuierliche Strukturen abzubilden**
  → Modellierung **relationaler Struktur**, nicht der linearen Anordnung
  → Dependenzstruktur **abstrahiert von der linearen Anordnung**
  → **bei Verarbeitung** (Parsing) können **nicht-projektive Strukturen aber problematisch** sein

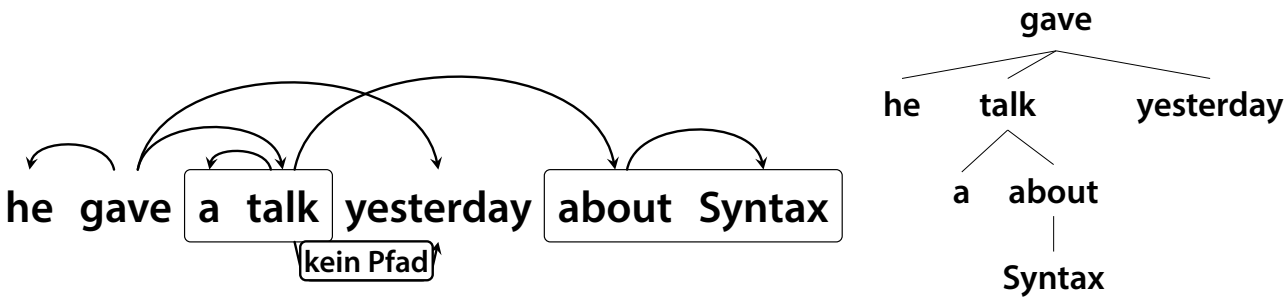

Abbildung 3: *Dependenzanalyse diskontinuierlicher = nicht-projektiver Struktur (mit und ohne Berücksichtigung linearer Ordnung)*

Auflistung 4: *NLTK: nicht-projektive Dependenzgrammatik*

```
1  #non-projective dep parsing im nltk
2  #http://www.nltk.org/howto/dependency.html
3
4  from nltk.grammar import DependencyGrammar
5  grammar = DependencyGrammar.fromstring("""
6      'gave' → 'he' | 'talk' | 'yesterday'
7      'talk' → 'a' | 'about'
8      'about' → 'Syntax'
9      """)
10
11 from nltk import NonprojectiveDependencyParser
12 dp = NonprojectiveDependencyParser(grammar)
13 g, =
     dp.parse(['he','gave','a','talk','yesterday','about
14 print(g.root['word'])
```

```
15 #gave
16 for _, node in sorted(g.nodes.items()):
17         if node['word'] is not None:
18             print('{address} {word}:
                   {d}'.format(d=node['deps'][''],
                   **node))
19 #1 he: []
20 #2 gave: [1, 4, 5]
21 #3 a: []
22 #4 talk: [3, 6]
23 #5 yesterday: []
24 #6 about: [7]
25 #7 Syntax: []
26 print(g.tree())
27 #(gave he (talk a (about Syntax)) yesterday)
```

12.2.2 Übergangsbasiertes Dependency-Parsing

- **Literatur**: Speech and Language Processing (Ed. 3). Daniel Jurafsky & James H. Martin. **Chapter 14**: `https://web.stanford.edu/~jurafsky/slp3/14.pdf`
- **Induktion** von Dependenz-Parsing-Modellen **aus Treebanks**
- **Dependency-Treebanks** können direkt von **Experten erstellt** sein oder **abgeleitet aus Phrasenstruktur-Treebanks (s. u.)**

Übergangsbasiertes Parsing

- verwendet Stack-basierten **Shift-Reduce-Algorithmus**
- `SHIFT`-**Operation**: Wörter in **Wortliste** (Buffer) auf Stack
  $\rightarrow$ Stack wird mit `root`-Knoten **initialisiert**
  $\rightarrow$ Abschluss, wenn Wortliste leer und nur noch `root` auf Stack
- `REDUCE`-**Operation**:
  $\rightarrow$ statt Ersatz durch Nonterminal (CFG):
  $\Rightarrow$ **Hinzufügen von Relation zwischen den beiden obersten Elementen auf dem Stack**
  $\Rightarrow$ **Löschen des Dependents vom Stack**

- **2 mögliche `REDUCE`-Operationen** (je nach Position Kopf):
  - **LEFTARC** = *head-final*: the $\leftarrow$ flights
  - **RIGHTARC** = *head-initial*: book $\rightarrow$ me
  - (für Labeling: Subdifferenzierung in `RIGHTARC(nsubj)` usw.)
- Je nach ***Konfiguration von Stack, Buffer und Menge der erkannten Relationen*** wird eine bestimmte **Operation ausgeführt** $\Rightarrow$ **Übergang** (***transition***)
  $\rightarrow$ bei CFG: Grammatikregeln entscheiden über Operation
  $\rightarrow$ hier: **Entscheidung** über anzuwendende Operation **durch trainiertes Modell**, dass **Konfigurationen auf Übergänge** abbildet

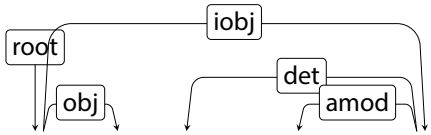

Step	Stack	Word List (Buffer)	Transition	Relation Added
0	[root]	[book, me, the, morning, flight]	SHIFT	
1	[root, book]	[me, the, morning, flight]	SHIFT	
2	[root, book, me]	[the, morning, flight]	RIGHTARC	(book $\rightarrow$ me)
3	[root, book]	[the, morning, flight]	SHIFT	
4	[root, book, the]	[morning, flight]	SHIFT	
5	[root, book, the, morning]	[flight]	SHIFT	
6	[root, book, the, morning, flight]	[]	LEFTARC	(morning $\leftarrow$ flight)
7	[root, book, the, flight]	[]	LEFTARC	(the $\leftarrow$ flight)
8	[root, book, flight]	[]	RIGHTARC	(book $\rightarrow$ flight)
9	[root, book]	[]	RIGHTARC	(root $\rightarrow$ book)
10	[root]	[]	Done	

Training übergangsbasiertes Parsing-Modell

- **Klassifikator**: sagt den **besten Übergang für die aktuelle Konfiguration** voraus
- wird durch anhand **von einer Treebank erzeugten Beispielen** trainiert
- Beispiele = **Konfiguration-Übergang-Paare**
  $\rightarrow$ Anwendung des Algorithmus auf die Sätze der Treebank
  $\rightarrow$ Verwendung der *head-dependent*-Relationen der Treebank zur **Bestimmung des Übergangsoperators** jeder Konfiguration

- bei jeder Konfiguration: **Abgleich**, ob eine **ARC-Operation eine Relation aus der Menge der Relationen** in der Referenzanalyse der Treebank für den Satz produziert
  → **Einschränkung bei *RIGHTARC***: nur, wenn der Dependent der möglichen Relation nicht Kopf einer der Relationen aus der Menge offener Relationen ist
  → Einschränkung verhindert, dass **Wort zu früh vom Stack** genommen wird

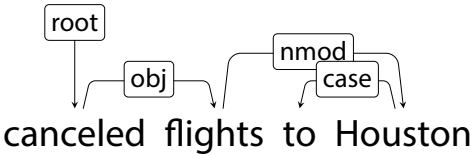

	Stack	Word List (Buffer)	Transition	
	[root,canceled,flights]	[to, Houston]	**SHIFT oder RIGHTARC ?**	
gewählte Operation				Relation Added
SHIFT	[root,canceled,flights,to]	[Houston]		-
RIGHTARC	[root,canceled]	[to, Houston]		(canceled → flights)

– **richtiger Übergang:** `SHIFT`

→ bei `RIGHTARC` wird *flights* zu früh vom Stack entfernt; Relation (*flights* → *Houston*) wäre dann nicht mehr möglich

- **Klassifikationsaufgabe**: **Einteilung von Konfigurationen** (Menge von Objekten) **in Klassen** (= **Übergangsoperationen**)
  → ***supervised learning***: **Klassen** (Übergänge) sind aus Trainingsdaten **bekannt**
  → Lernen einer **Funktion, die von Konfigurationen auf Übergangs-Operatoren** abbildet
- Konfigurationen werden **durch Merkmalsvektor repräsentiert**
- Merkmale werden durch **Feature-Extraktion** gewonnen

- **häufig verwendete Merkmale**:
  - **Token, Lemma und POS** von Wörtern **auf Stack** (die Obersten)
  - **Token, Lemma und POS** von Wörtern in **Wortliste** (die Vordersten)
  - **Relationen** zwischen den berücksichtigten Wörtern
- **verwendete Klassifikationsverfahren**: logistische Regression, Support Vector Machine oder Neuronale Netze (z. B.: `https://nlp.stanford.edu/software/nndep.shtml`)

Übergangsbasierte Parsing-Systeme:

- **Malt-Parser** (Nivre et al.): *transition-based Dependency Parser*
  → `http://maltparser.org`
- **Stanford-Dependency-Parser** (Manning et al.):
  - neben der **Transformation von** PCFG-geparsten **Konstituentenbäumen in Dependenzgraphen** (`englishPCFG.ser.gz`):
  - **Transition-based Dependency-Parsing-Modell:**
    → `englishFactored.ser.gz`: verwendet PCFG-Parser und Dependenz-Parser und vergleicht Ergebnisse
    → `https://nlp.stanford.edu/software/parser-faq.html#y`

12.2.3 Graphbasiertes Dependency-Parsing

Graphbasiertes Parsing

- **Suche im Raum möglicher Dependenzbäume** nach dem am besten bewerteten
- **Konstruktion von gerichtetem Graph** mit den **Wörtern des Satzes als Knoten** und allen möglichen ***head-dependent*-Relationen als Kanten**
- trainiertes Modell gibt **Gewichte für head-dependent-Relationen** (ähnlich wie bei PCFG)

- **Berechnung des Baumes** (Teilgraph) mit **maximalem Gewicht** (*maximum spanning tree*)
  $\rightarrow$ jeder Knoten außer Root-Knoten hat **genau eine eintreffende Kante** (Dependent hat genau einen Kopf)

- **Graph-basierter Parser: MSTParser** (Baldrige und McDonald)
  $\rightarrow$ `http://www.seas.upenn.edu/~strctlrn/MSTParser/MSTParser.html`

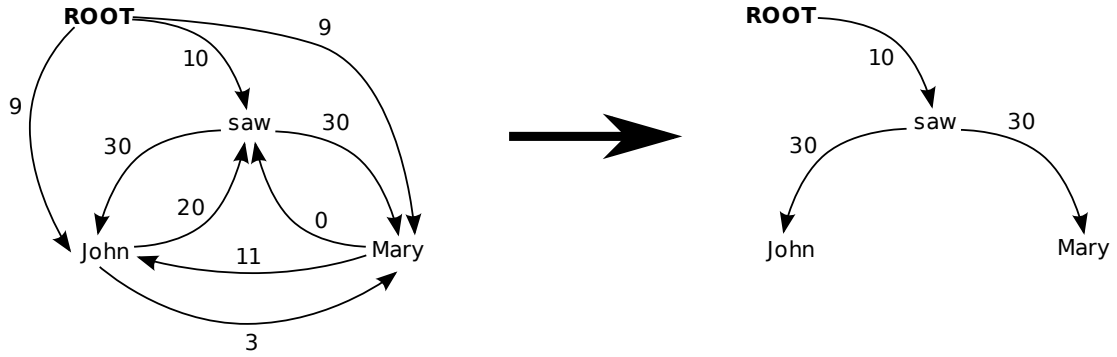

Abbildung 4: *Graph-basiertes Parsing,* `http://stp.lingfil.uu.se/~nivre/docs/eacl1.pdf`

Vorteile Graph-basiert

- **nicht-projektive Bäume** möglich
- Graphbasiert: **Bewertung ganzer Bäume** statt lokaler Entscheidungen basierend auf der jeweiligen Konfiguration
  $\rightarrow$ bessere ***accuracy*** **mit steigendem Abstand zwischen Kopf und Dependent**
- **ohne Backtracking** ist **nicht garantiert**, dass ein übergangsbasierter Parser die **optimale Lösung** findet
  $\rightarrow$ **Greedy-Algorithmus** basierend auf lokalen Entscheidungen

Evaluation von Dependenz-Parsing-Systemen

- **Überprüfung an Testmenge** (Teilmenge Dependency-Treebank)
- ***unlabeled attachment accuracy***: **korrekte Zuweisung Dependent zu Kopf**
- ***labeled attachment accuracy***: **korrekte Zuweisung** und **korrekte Relation** zwischen Dependent und Kopf

12.2.4 *Dependency-Treebanks*

- von Experten erstellte **dependenzsyntaktisch annotierte Korpora (relationsannotierte Tokenlisten)**
- Einsatz zu **Training und Evaluation** von Dependenz-Parsing-Systemen

- ***Dependency-Treebanks*** können auch **aus PSG-Treebanks** gewonnen werden (s. Sitzung 5)
  → **Transformation** von **kopfannotierten Konstituenten-Bäumen** in einen Dependenzgraph:
  1. **Finden aller *head-dependent*-Relationen** über *head-finding-rules*
  2. **Labeln der Relationen** über handgeschrieben Regeln
     → Bestimmung Relationstyp **über Strukturposition**:
     `NP mit Mutterknoten S ist` **`subj`**
     → bei Penn-Treebank: Verwendung **funktionaler Informationen in den Nichtterminalen**: `NP-SBJ`

Funktionale Kategorien in Penn Treebank

- **Grammatische Relationen/funktionale Angaben** in den phrasalen Kategorien, z. B.: `NP-SBJ`
  → `PP-CLR`: 'closely related', z. B. für präpositionales Objekt
  → `NP-PUT`: adverbiales Komplement von *put*
  → `NP-ADV`: für Kasusadverbial
  → `http://web.mit.edu/6.863/www/PennTreebankTags.html`

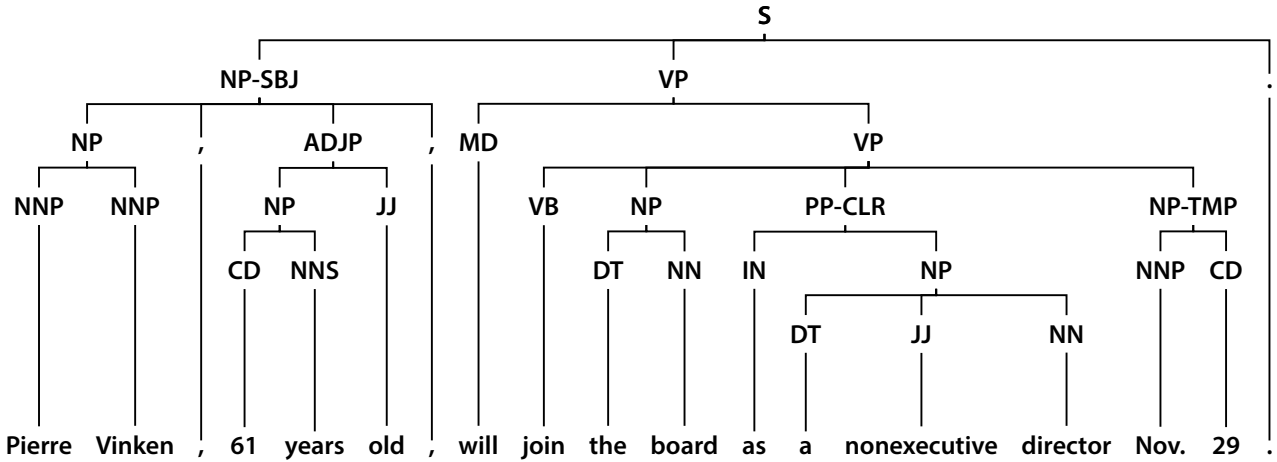

Abbildung 5: *Beispiel-Parse Satz aus Penn-Treebank*

Dependency Tagsets:

- **Stanford Dependencies**:

  `https://nlp.stanford.edu/software/dependencies_manual.pdf`

- **Universal Dependencies** (basiert u.a. auf *Stanford Dependencies*; Stanford Parser verwendet in neuester Version UD-Tagset)

  `http://universaldependencies.org/u/dep/all.html`

Dependency Treebanks:

- PDT = Prague Dependency Treebank (>1.5 Mill Tokens)
- **UD Treebanks** (> 30 Sprachen):

  `http://universaldependencies.org/`

  $\rightarrow$ 2 Deutsche UD-Treebanks im CoNLL-Format:

  `http://universaldependencies.org/de/index.html`

CoNLL-Dependency-Treebanks

- CoNLL = *Conference on Computational Natural Language Learning*
- Shared Tasks zu **Dependency Parsing**: mit annotierten Treebanks für Evaluation der Systeme (*training, dev und gold standard*)
- **TIGER Dependency Bank** (in Dependency-Format konvertiertes TIGER-Korpus, deutsch) verwendet in CoNLL und UD-Treebanks, konvertiert in Stanford bzw. Universal Dependencies

Dependenz-Formate:

- **CoNLL-Formate**
  → in UD-Framework: CoNLL-U
  → `http://universaldependencies.org/format.html`
- **dot-Format**
  → Visualisierung mit graphviz (`display()` im NLTK)
- NLTK: **DependencyGraph**-Objekt (z. B. mit Stanford-Dep-Parser)
- NLTK **Ausgabemethoden** für *DependencyGraph*:
  `to_dot()`, `to_conll()`, `triples()`

1	Alle	alle	PRON	PIS	Case=Nom..	2	nsubj	_	_
2	wußten	wissen	VERB	VVFIN	Number=Plur..	0	root	_	SpaceAfter=No
3	,	,	PUNCT	$,	_	2	punct	_	_
4	daß	daß	SCONJ	KOUS	_	10	mark	_	_
5	uns	wir	PRON	PPER	Case=Dat..	10	iobj	_	_
6	nicht	nicht	PART	PTKNEG	Polarity=Neg	7	advmod	_	_
7	mehr	mehr	ADV	ADV	_	10	advmod	_	_
8	viel	viel	ADJ	PIAT	Case=Nom..	9	amod	_	_
9	Zeit	Zeit	NOUN	NN	Case=Nom..	10	nsubj	_	_
10	blieb	bleiben	VERB	VVFIN	Number=Sing..	2	ccomp	_	SpaceAfter=No
11	.	.	PUNCT	$.	_	2	punct	_	_

Tabelle 1: *CoNLL-Format (komplexer Satz aus dem deutschen UD-Korpus)*

Auflistung 5: *NLTK: Umwandlung von CoNLL-Format zu dot-Format*

```
#http://www.nltk.org/howto/dependency.html
#http://www.nltk.org/_modules/nltk/parse/dependencygr
from nltk import DependencyGraph
dg = DependencyGraph(treebank_data)
print(dg.to_dot())
# digraph G{
# 0 [label="0 (None)"]
# 0 -> 2 [label="root"]
# 1 [label="1 (Alle)"]
# 2 [label="2 (wußten)"]
# 2 -> 1 [label="nsubj"]
# 2 -> 3 [label="punct"]
# 2 -> 11 [label="punct"]
# 2 -> 10 [label="ccomp"]
# 3 [label="3 (,)"]
```

```
# 4 [label="4 (daß)"]
# 5 [label="5 (uns)"]
# 6 [label="6 (nicht)"]
# 7 [label="7 (mehr)"]
# 7 → 6 [label="advmod"]
# 8 [label="8 (viel)"]
# 9 [label="9 (Zeit)"]
# 9 → 8 [label="amod"]
# 10 [label="10 (blieb)"]
# 10 → 4 [label="mark"]
# 10 → 5 [label="iobj"]
# 10 → 7 [label="advmod"]
# 10 → 9 [label="nsubj"]
# 11 [label="11 (.)"]
# }
```

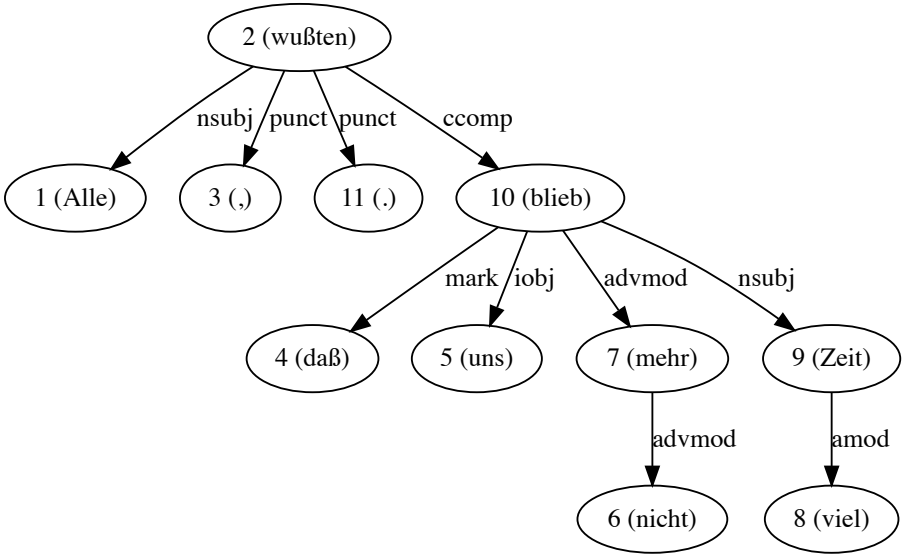

Abbildung 6: *Visualisierung UD-German-Korpus (CoNLL) mit graphviz*

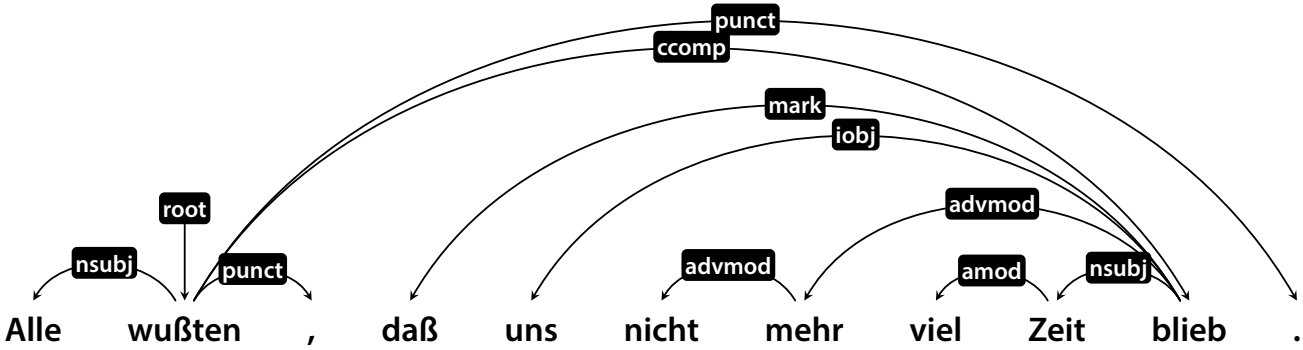

Abbildung 7: *Satz aus Dependency-Treebank* UD-german *im LateX-tikz-dependency-Format*